

CURSO DE GRADUAÇÃO EM ENGENHARIA DA COMPUTAÇÃO

Gabriel Augusto Baierle

**DESENVOLVIMENTO DE METODOLOGIA COMPUTACIONAL PARA ANÁLISE
DE INFESTAÇÃO POR *EPITRIX* NO TABACO**

Santa Cruz do Sul

2017

Gabriel Augusto Baierle

**DESENVOLVIMENTO DE METODOLOGIA COMPUTACIONAL PARA ANÁLISE
DE INFESTAÇÃO POR *EPITRIX* NO TABACO**

Trabalho de conclusão de curso de graduação
apresentado ao Departamento de Computação da
Universidade de Santa Cruz do Sul como requisito
parcial para a obtenção do título de Bacharel em
Engenharia da Computação.

Área de habilitação: Computação

Orientador: Prof. Dr. Rolf Fredi Molz
Co-Orientador: Prof. Dr. Andreas Kohler

Santa Cruz do Sul

2017

RESUMO

O objetivo deste trabalho é desenvolver um método computacional para a análise de infestação por *Epitrix* spp. em folhas de tabaco. Com este método pretende-se oferecer mais precisão e agilidade ao processo de análise de infestação nas lavouras, que atualmente é feito de forma manual. O desenvolvimento do sistema se deu por meio do processamento de imagens, envolvendo as etapas de aquisição, pré-processamento, segmentação, representação e reconhecimento e interpretação. A coleta dos dados será realizada em campo, ou seja, foram adquiridas imagens de folhas de tabaco em lavouras de Santa Cruz do Sul. O desenvolvimento das diferentes etapas e métodos para o processamento das imagens foi feito utilizando a linguagem de programação C++ em conjunto com a biblioteca *OpenCV* (*Open Source Computer Vision Library*). Para a segmentação das imagens foram desenvolvidos quatro métodos: a segmentação binária utilizando limiar fixo, a segmentação binária com limiar calculado a partir do mínimo e máximo dos pixels, a segmentação utilizando o método desenvolvido por Barbedo (2016) e a segmentação através da análise do canal H do modelo HSI. Os dados obtidos com a segmentação foram representados pelo diâmetro das regiões segmentadas com a presença de mordidas da praga através da detecção de *Blobs*. Para validar o sistema, estes dados foram comparados com segmentações e estimativas do número de mordidas realizadas manualmente por um técnico. Os melhores resultados foram obtidos pelos métodos de limiarização com valor fixo, que obteve uma precisão de 53%, e de limiarização pelo método de Barbedo (2016), que teve 77% de sensibilidade. No entanto, todos os métodos tiveram uma taxa de erro elevada, acima de 74%. Esta taxa pode ser minimizada através da padronização dos parâmetros de aquisição das imagens ou ainda com a utilização de um classificador na etapa final do processamento. Ambos ficam como sugestões de trabalhos futuros.

Palavras chave: Análise de infestação, *Epitrix*, processamento de imagens digitais.

ABSTRACT

This work aims to develop a software for the analysis and detection of *Epitrix* spp. Infestations in tobacco leaves. The software intends to be more precise and faster than the manual method used to analyze infestations in crops nowadays. The system will be developed by means of image processing, which involves the steps of acquisition, pre-processing, segmentation, representation and recognition and interpretation. The input data, that is, the images of tobacco leaves, will be collected in crops located in Santa Cruz do Sul. The development of the software and the methods for image processing will be in C++ programming language using the OpenCV library (*Open Source Computer Vision Library*). Four methods were developed to segment the images: binary thresholding using a fixed threshold, binary thresholding calculating the threshold based on minimal and maximum pixel values, segmentation using the method proposed by Barbedo (2016) and the segmentation using the H channel from HSI model. The segmented data was represented by the diameter of the regions bitten by the *Epitrix*, which could be obtained by the Blob detection. In order to validate the proposed system, this data was compared to the data manually segmented by a technician. The best results were obtained by the threshold with fixed threshold, which obtained 53% of precision, and the segmentation using Barbedo method (2016), which obtained 77% of sensibility. On the other hand, all methods obtained a high error rate, below 74%. This rate can be minimized by defining default parameter in image acquisition and by using a classifier in the final stages of the image processing. Both alternatives remain as future work.

.

Keywords: Infestation analysis, *Epitrix*, digital image processing.

LISTA DE FIGURAS

Figura 1 – Tabaco adulto, já transplantado na lavoura.	13
Figura 2 - <i>Epitrix</i> spp. adulto.....	16
Figura 3 - Folha de tabaco com perfurações causadas pelas mordidas do <i>Epitrix</i> spp....	17
Figura 4 - Região de interesse na contagem de mordidas do <i>Epitrix</i>	18
Figura 5 - Etapas do processamento de imagens.	19
Figura 6 - Imagem original (à esquerda) e após aplicação de erosão (à direita)..	23
Figura 7 - Imagem original (à esquerda) e após aplicação de dilatação (à direita).....	24
Figura 8 - Imagem original (à esquerda) e após aplicação de abertura (à direita).	24
Figura 9 - Imagem original (à esquerda) e após aplicação de fechamento (à direita).	25
Figura 10 - Detecção de bordas pelo cálculo de derivadas	26
Figura 11 - Gradiente em uma borda.	27
Figura 12 - <i>Kernels</i> utilizados pelos operadores Prewitt, Sobel e Roberts.	27
Figura 13 - Imagem contendo vários <i>blobs</i>	29
Figura 14 - Resultado para o método de segmentação.....	32
Figura 15 - Comparação dos resultados do método proposto	33
Figura 16 – Resultado da segmentação realizada pelo autor.	33
Figura 17 - Resultados da segmentação de 20 imagens.....	34
Figura 18 - Demonstração do resultado da segmentação.	35
Figura 19 - Categorias para a classificação da severidade da infestação.	36
Figura 20 - Resultado da segmentação	36
Figura 21 - Exemplo de imagem segmentada.	37
Figura 22 - Técnicas utilizadas em cada etapa do processamento de imagens.....	40
Figura 23 - À esquerda a imagem original e a direita após o tratamento inicial para o processamento.....	41
Figura 24 - Imagem para escala de cinza.	42
Figura 25 - Regra para conversão RGB para HSI.	42
Figura 26 - Antes e depois da aplicação do filtro Gaussiano.	43
Figura 27 – Antes e depois da aplicação da operação de abertura.	43
Figura 28 - Limiarização binária com limiar fixo.	44
Figura 29 - Limiarização binária utilizando mínimo e máximo.	45
Figura 30 - Regiões claras destacadas pelo método de Barbedo (2016).	46

Figura 31 - Imagem convertida para o modelo HSI.....	46
Figura 32 - Canal H e seu histograma.	47
Figura 33 - Imagem segmentada manualmente (esquerda) e pelo método 1 (direita).	52
Figura 34 - Imagem segmentada manualmente (esquerda) e pelo método 1 (direita).	53
Figura 35 - Imagem segmentada manualmente (esquerda) e pelo método 1 (direita).	53
Figura 36 - Imagem segmentada manualmente (esquerda) e pelo método 2 (direita).	54
Figura 37 - Imagem segmentada manualmente (esquerda) e pelo método 2 (direita).	54
Figura 38 - Imagem segmentada manualmente (esquerda) e pelo método 3 (direita).	55
Figura 39 - Imagem segmentada manualmente (esquerda) e pelo método 4 (direita).	55
Figura 40 - Imagem segmentada manualmente (esquerda) e pelo método 4 (direita).	55
Figura 41- Validação da imagem 1.	58
Figura 42 - Validação da imagem 2.	58

LISTA DE TABELAS

Tabela 1 - Produção mundial de tabaco na safra de 2015/16.	14
Tabela 2 - Comparativo entre os trabalhos selecionados.....	38
Tabela 3 - Tabela de diâmetros dos pontos encontrados para cada método de segmentação.	49
Tabela 4 - Número de mordidas estimado para cada metodologia.....	51
Tabela 5 - Comparação da análise manual com as metodologias empregadas.	57
Tabela 6 - Composição básica da matriz de confusão.....	59
Tabela 7 - Matriz de confusão para o método 1.....	59
Tabela 8 - Matriz de confusão para o método 2.....	60
Tabela 9 - Fonte: Matriz de confusão para o método 3.	60
Tabela 10 - Matriz de confusão para o método 4.....	60
Tabela 11 - Métricas dos métodos testados.	61

SUMÁRIO

1	INTRODUÇÃO	9
2	JUSTIFICATIVA	11
3	OBJETIVOS	12
3.1	Objetivo geral.....	12
3.2	Objetivos específicos.....	12
4	FUNDAMENTAÇÃO TEÓRICA.....	13
4.1	A Cultura do Tabaco.....	13
4.2	Características do <i>Epitrix</i> spp.....	16
4.3	Processamento de Imagens Digitais	19
4.3.1	Aquisição.....	19
4.3.2	Pré-processamento.....	20
4.3.2.1	Modelos de Cores	20
4.3.2.2	Realce de Imagens	21
4.3.2.3	Filtros Passa-Baixa.....	22
4.3.2.4	Transformações Morfológicas.....	23
4.3.3	Segmentação	25
4.3.3.1	Limiarização	25
4.3.3.2	Detecção de Bordas	26
4.3.3.3	Transformada de Hough	28
4.3.3.4	Detecção de <i>Blobs</i>	29
4.3.4	Representação e Descrição	29
4.3.5	Reconhecimento e Interpretação	30
5	TRABALHOS RELACIONADOS	31
5.1	<i>A new automatic method for disease symptom segmentation in digital photographs of plant leaves</i>	<i>31</i>
5.2	<i>An image-processing based algorithm to automatically identify plant disease visual symptoms</i>	<i>33</i>
5.3	<i>Leaf disease severity measurement using image processing.....</i>	<i>35</i>
5.4	<i>A new colour vision system to quantify automatically foliar discoloration caused by insect pests feeding</i>	<i>36</i>
5.5	<i>Grading method of leaf spot disease based on image processing</i>	<i>37</i>

5.6	Considerações	38
6	TRABALHO PROPOSTO	40
6.1	Visão geral.....	40
6.2	Aquisição	41
6.3	Pré-processamento.....	42
6.4	Segmentação.....	43
6.4.1	Método um: Limiarização binária com limiar fixo	44
6.4.2	Método Dois: Limiarização binária utilizando mínimo e máximo.....	44
6.4.3	Método três: Segmentação utilizando o método proposto por BARBEDO (2016).....	45
6.4.4	Método quatro: Segmentação utilizando canal H do modelo HSI	46
6.5	Representação e Descrição.....	48
6.6	Reconhecimento e Interpretação.....	50
7	VALIDAÇÃO	52
8	CONCLUSÃO.....	62
	REFERÊNCIAS	64

1 INTRODUÇÃO

A indústria fumageira é a principal fonte da economia da cidade de Santa Cruz do Sul desde os primeiros anos após a colonização da cidade e da região pelos imigrantes alemães. Anualmente, a produção de tabaco acumula cerca de 15 mil toneladas, sendo responsável pela geração de mais de 13 mil empregos e respondendo atualmente por cerca de 65% da economia local (NEUMANN, ROMERO, 2013).

O cultivo do tabaco exige cuidados e atenção constantes, pois como o produto final são suas folhas, se essas forem atacadas por insetos e pragas, sua qualidade pode reduzir consideravelmente, diminuindo o seu preço e valor para a indústria (BREITBACH, 2014).

Dentre as várias pragas agrícolas conhecidas que prejudicam o seu cultivo, encontra-se o *Epitrix* spp., que é responsável por graves injúrias nas do tabaco. De acordo com uma amostragem realizada em duas safras, nos anos de 2011/2012 e 2012/2013, foram coletados 54.201 indivíduos do *Epitrix* em lavouras de tabaco no município de Santa Cruz do Sul (KOEHLER; MORAES; OLIVEIRA, 2017).

Os insetos adultos atacam as folhas, principalmente as mais novas e inferiores, onde se alimentam próximo à veia central, causando perfurações que diminuem o peso e a qualidade das folhas do tabaco. A incidência do inseto é mais frequente no final do ciclo do fumo, próximo ao período de colheita, quando a proteção de inseticidas perde grande parte do seu efeito e é proibida (GUEDES; SULZBACH, 2006).

A detecção do nível de incidência do *Epitrix* em uma lavoura é feito através da contagem de mordidas do inseto em algumas amostras de folhas. Essa contagem é feita em uma região da folha determinada pelo posicionamento de um quadrado entre a veia central e uma das bordas da folha. Atualmente, essa contagem é feita de forma manual por um técnico que analisa individualmente as folhas amostradas e estima o número de mordidas e o nível de infestação.

Essa análise manual traz uma série de desvantagens, como o custo e o tempo necessários para ser realizada, bem como a variação na precisão com que é feita. Por este motivo, não é nenhuma surpresa que métodos para o diagnóstico automático de doenças em plantas estejam recebendo atenção e investimentos especiais. Dentre estes métodos pode-se citar a utilização do processamento e extração de informações de imagens digitais.

Sabendo disso, este trabalho propõe o desenvolvimento de um método computacional para realizar a contagem de mordidas do *Epitrix* em folhas de tabaco utilizando técnicas de processamento de imagem. Com o desenvolvimento dessa ferramenta espera-se oferecer uma

alternativa para a detecção de infestações da praga nas lavouras, eliminando o caráter manual com que esta é feita atualmente e oferecendo mais precisão e agilidade no processo.

Para a fundamentação teórica deste trabalho, foi elaborada uma descrição sobre o cultivo do tabaco e sobre as características do *Epitrix*. Estas informações se encontram no capítulo 4. Na fundamentação teórica também estão descritas as diferentes etapas para o processamento de imagens e as principais técnicas empregadas em cada uma delas.

Também foi realizado um estudo de trabalhos relacionados ao sistema proposto. Foram estudados os trabalhos desenvolvidos e publicados por Barbedo (2016), Camargo; Smith (2009), Patil; Bodhe (2011), Clement *et al.* (2015) e Weizheng *et al.* (2008). Estes trabalhos utilizam processamento de imagem para a identificação de sintomas em imagens de folhas de plantas e propõem diferentes formas de segmentação. A descrição de cada um deles se encontra no capítulo 5.

O capítulo 6 descreve o sistema proposto, apresentando os métodos que foram implementados e para se alcançar os objetivos do trabalho. Já o capítulo 7 detalha a validação do trabalho, descrevendo os resultados comparando-se os dados obtidos pelo sistema e pela segmentação manual realizada por um técnico.

Por fim, o capítulo 8 contém as conclusões do trabalho desenvolvido, considerações sobre os resultados alcançados e sugestões de trabalhos futuros.

2 JUSTIFICATIVA

O problema que este trabalho almeja resolver é: como realizar a análise de infestação por *Epitrix* em folhas de tabaco utilizando processamento de imagem?

O *Epitrix* é uma praga que se alimenta das folhas de tabaco e as deixa com perfurações resultantes da sua mordida. Tais perfurações podem variar de tamanho, fazendo com que as folhas de tabaco percam peso e, conseqüentemente, percam seu valor comercial, o que não é interessante para o fumicultor, que ganhará menos por seu produto, nem para a indústria, que receberá um produto de menor qualidade. Adicionalmente, as larvas do *Epitrix*, que ficam depositadas no solo, também se alimentam das raízes das plantas (GUEDES; SULZBACH, 2006).

Para evitar tamanhas perdas é de fundamental importância que a detecção de infestações e doenças em lavouras seja realizada de forma precisa e no tempo certo. Em sua grande maioria, essa detecção é feita visualmente por pessoas. Esse aspecto manual traz uma série de desvantagens, como o custo com treinamentos e contratação de pessoas especializadas, variações na precisão das detecções, estimativas imprecisas do número ou tamanho de uma infestação, ou ainda a degradação de amostras caso estas sejam colhidas para análise posterior em laboratório.

Desta forma, a justificativa e a motivação para a realização deste trabalho está nas consequências negativas causadas pela infestação de *Epitrix* nas lavouras de tabaco, que são tão importantes para a economia regional, e no carácter manual com que é feita a análise da infestação pelo inseto. Portanto, com o desenvolvimento deste trabalho pretende-se ganhar em eficiência e agilidade nessa análise.

A justificativa científica para o trabalho fica por conta do estudo e da utilização de conceitos de processamento de imagens digitais para solucionar o problema.

3 OBJETIVOS

3.1 Objetivo geral

O objetivo geral deste trabalho é desenvolver um método computacional para a análise de infestação por *Epitrix* em folhas de tabaco e, para tal, realizar a contagem do número de mordidas do inseto através do processamento de imagens digitais.

3.2 Objetivos específicos

Para alcançar o objetivo final deste trabalho, pretende-se atingir os seguintes objetivos específicos:

- Entender as características do *Epitrix* e de que forma diagnosticar uma possível infestação;
- Compreender as etapas e diferentes técnicas de processamento de imagens;
- Analisar e definir a melhor metodologia na solução do problema que o trabalho almeja resolver;
- Estudar os métodos e a utilização da biblioteca *OpenCV*;
- Desenvolver uma metodologia para a localização e contagem das mordidas do *Epitrix*;
- Testar e validar a aplicação desenvolvida.

4 FUNDAMENTAÇÃO TEÓRICA

Este capítulo consiste de uma descrição do referencial teórico estudado para a realização deste trabalho. Primeiramente, com o intuito de entender melhor de que forma é feito e qual a sua importância mundial e localmente, é feita uma apresentação da cultura do tabaco. Também foi realizado um detalhamento a respeito do *Epitrix*, abordando suas principais características e consequências para o cultivo do tabaco, uma vez que o objetivo deste trabalho é a contagem de mordidas da praga em folhas da planta.

O capítulo consiste também na descrição das etapas e dos processos fundamentais para o processamento de imagens, abordando as diversas técnicas e sua importância em cada uma das etapas para o desenvolvimento de um sistema baseado na obtenção de informações de imagens digitais.

4.1 A Cultura do Tabaco

O tabaco (Figura 1), de nome científico *Nicotiana Tabacum L.*, é uma planta pertencente à família *Solanaceae*, juntamente com plantas como o tomate, berinjela, pimenta e batata. Ele é utilizado como matéria-prima para a fabricação de diversos produtos, como pesticidas e remédios, porém seu maior valor econômico provém da produção de drogas recreativas, como cigarros, charutos e cachimbos. A planta pode atingir até 2 metros de altura e pode ser cultivado em uma grande amplitude de climas, porém necessita de um período sem geadas até o final da colheita, de uma temperatura média de 20° a 30° C e solos bem arejados e drenados (OLIVEIRA; COSTA, 2012).

Figura 1 – Tabaco adulto, já transplantado na lavoura.



Fonte: KIST *et al.*, 2016.

O plantio do tabaco é dividido entre a produção das mudas e o cultivo em lavoura (SOUZA CRUZ, 2017). A produção das mudas consiste no seu plantio em viveiros, o que é feito entre os meses de junho e julho. Depois de cerca de dois meses, quando as plantas

atingirem aproximadamente 15 a 20 centímetros de altura, elas estão prontas para serem transplantadas no campo, onde crescem por mais dois ou três meses. A próxima etapa é a colheita, que deve acontecer entre outubro e dezembro.

A forma de colheita varia de acordo com o tipo de tabaco; o tabaco do tipo Virgínia, que é o mais cultivado no Brasil, é colhido folha a folha, enquanto que o do tipo *Burley* é colhido inteiro. Após a colheita, o tabaco passa pelo processo de cura, que também pode se dar de diferentes formas. O tabaco do tipo *Burley* é curado através do contato com o ar, o do tipo Oriental é curado pela exposição ao sol, e o tabaco do tipo Virgínia é curado em estufas (PHILIP MORRIS, 2017).

O cultivo da planta, bem como seu uso através do ato de mascar, fumar ou inalar, já eram costumes tradicionais indígenas no continente americano. Com a chegada dos colonizadores por volta dos anos 1500, esses costumes foram introduzidos aos europeus e o tabaco tornou-se uma importante moeda de troca, espalhando-se gradativamente pela Europa e pelo mundo (OLIVEIRA; COSTA, 2012).

Atualmente, mesmo com a diminuição no consumo de cigarros, a produção de tabaco continua sendo uma das atividades mais importantes para a economia de vários países. A produção mundial é liderada pela China, que na safra 2015/2016 produziu mais de 2 milhões de toneladas, seguida pelo Brasil, Índia, Estados Unidos e Zimbábue. Estes países juntos correspondem a cerca de 70% da produção mundial, conforme se pode ver pela Tabela 1, que mostra o total produzido pelos 10 maiores países produtores na safra 2015/2016 (KIST *et al.*, 2016).

Tabela 1 - Produção mundial de tabaco na safra de 2015/16.

Países	Toneladas
1. China	2.372.000
2. Brasil	538.683
3. Índia	365.000
4. Estados Unidos	298.230
5. Zimbábue	202.000
6. Malaui	198.390
7. Indonésia	188.275
8. Turquia	169.660
9. Paquistão	105.549
10. Argentina	96.362
Outros	1.194.460
TOTAL	5.728.609

Fonte: adaptado de KIST *et al.*, 2016.

Como pode ser visto na tabela, o Brasil ocupa o segundo lugar como produtor mundial, produzindo cerca de 538 mil toneladas de tabaco durante a safra de 2015/2016.

Deste total, cerca de 516 mil toneladas foram destinadas à exportação, o que corresponde a aproximadamente 95% do que foi produzido. Estes números colocam o Brasil como líder mundial na exportação de tabaco, posição que ocupa desde 1993. (KIST *et al.*, 2016)

A região Sul tem um impacto muito grande na produção nacional de tabaco, sendo responsável por 97% do total produzido. Segundo Kist *et al.* (2016), só o Rio Grande do Sul produziu cerca de 255 mil toneladas na safra 2015/2016. Para suportar essa produção, segundo dados estimados pela Associação dos Fumicultores do Brasil (Afubra) em 2016, a região Sul do Brasil conta com 150,2 mil famílias e 2.983,5 mil hectares destinados para a produção de tabaco.

A cidade de Santa Cruz do Sul também possui sua parcela de contribuição para esses números, onde o tabaco é cultivado por imigrantes alemães desde o século XIX. A produção e o cultivo se expandiram e profissionalizaram, sobretudo a partir da implantação da *British American Tobacco* (BAT) na região em 1918. Desde então a produção de tabaco e a indústria fumageira ainda são a principal atividade econômica para a cidade, sendo responsável por cerca de 65% da economia local e pela geração de aproximadamente 13 mil empregos (NEUMANN; ROMERO, 2013). A produção anual é de aproximadamente 15 mil toneladas, e caracteriza-se por se dar em propriedades familiares com em média 15,2 hectares onde os próprios membros da família costumam trabalhar em todas as etapas da produção (BREITBACH, 2014).

O cultivo do tabaco, como o de qualquer outra espécie de planta, exige cuidados e atenção constantes, pois existem diversas espécies de pragas prejudiciais ao seu desenvolvimento. Os números dos danos causados por pragas e doenças em plantas são bastante elevados, e em alguns casos as perdas podem ser totais. O Brasil, por apresentar clima tropical e extensas áreas cultivadas, favorece o desenvolvimento de determinadas espécies de pragas. Estima-se que as pragas são responsáveis por uma perda anual de 2,2 bilhões de dólares para as principais culturas brasileiras, dentre elas o tabaco (MORAES, 2017).

Dependendo da cultura, os danos causados por pragas e infestações podem se manifestar de forma direta, quando os ataques são às partes destinadas à comercialização, ou indireta quando as partes danificadas são as que não serão comercializadas (GALLO *et al.*, 2002). Como o produto final do tabaco são as folhas, se estas forem atacadas por insetos e pragas, os danos serão diretos e sua qualidade pode reduzir consideravelmente, diminuindo seu preço e valor para a indústria. Dentre as espécies que atacam as folhas de tabaco e podem

trazer grandes prejuízos à produção, está o *Epitrix* spp. As características desta praga e suas consequências para as lavouras serão tratadas no próximo capítulo.

4.2 Características do *Epitrix* spp.

O *Epitrix* spp. (Figura 2), popularmente conhecido como pulga do fumo, é um inseto da ordem *Coleoptera*, sendo, portanto, semelhante a um besouro. O inseto adulto pode medir de 1,5 a 2 milímetros de comprimento e pode apresentar coloração parda, preta ou por vezes escura com manchas marrons. Ele se hospeda principalmente em plantas da família *Solanaceae*, como por exemplo, tomate, batata, berinjela e também o tabaco (GUEDES; SULZBACH, 2006).

Figura 2 - *Epitrix* spp. adulto.



Fonte: GUEDES; SULZBACH, 2006.

O *Epitrix* representa uma ameaça para seus hospedeiros durante todo o seu ciclo de vida. A fase larval do inseto ocorre no solo, onde são depositados seus ovos. Durante esse período, as larvas alimentam-se das raízes das plantas e de tubérculos, como a batata, prejudicando seu crescimento e podendo provocar lesões e rachaduras. Em cerca de uma semana emergem os adultos, então o inseto deixa o solo e passa a se alimentar da estrutura e principalmente das folhas da planta hospedeira.

No tabaco, o inseto se alimenta próximo à veia central das folhas, onde acaba causando perfurações com sua mordida (Figura 3). Essas perfurações diminuem o peso da folha, fazendo com que ela perca qualidade e, conseqüentemente, perca parte de seu valor comercial. Além disso, as larvas do *Epitrix*, que ficam no solo, se alimentam das raízes do tabaco, causando lesões que permitem a entrada de microrganismos que podem causar outras doenças à planta. O ciclo de vida do *Epitrix* é de cerca de 60 dias. Portanto, em uma lavoura de tabaco podem existir até 3 ou 4 gerações do inseto (GUEDES; SULZBACH, 2006).

Figura 3 - Folha de tabaco com perfurações causadas pelas mordidas do *Epitrix* spp.



Fonte: Disponível em <<http://www.agronomicabr.com.br/agriporticus/detalhe.aspx?id=582>>.

Segundo Bieńkowski; Bienkowskaja (2016) existem cerca de 180 espécies do *Epitrix* distribuídas mundialmente, sendo que a maioria das espécies conhecidas concentra-se nas Américas do Sul e Central, e algumas também foram identificadas na América do Norte e na Europa.

No continente europeu o *Epitrix* constitui uma ameaça para a produção de batata, que é uma das principais culturas cultivadas. Em 2012, alguns países da União Europeia firmaram um acordo com medidas emergenciais contra o *Epitrix*, estabelecendo que a importação de batatas só fosse aceita se cultivadas em uma região livre de pestes ou se tivessem passado por algum processo de higienização. Esse acordo visou, com isso, reduzir os riscos de novas infestações e evitar que o inseto se espalhe pelo continente (EYRE; GILTRAP, 2012).

Em Santa Cruz do Sul, os danos causados pelo *Epitrix* afetam o principal produto da economia local: o tabaco. De acordo com Koehler, Moraes, Oliveira (2017), em uma amostragem feita em lavouras de tabaco no município de Santa Cruz do Sul durante as safras 2011/2012 e 2012/2013, foram coletados um total de 54201 indivíduos do inseto. As coletas foram realizadas semanalmente durante os meses finais de safra, tanto em lavouras onde o cultivo é feito de forma convencional como em lavouras de manejo orgânico, onde não são utilizados agrotóxicos.

As infestações por *Epitrix* geralmente são controladas com o uso de inseticidas. Porém, quando os seus danos ficam mais evidentes nas folhas do tabaco, por exemplo, este já está bem próximo ou pronto para a colheita, tornando difícil um novo tratamento e muitas vezes obrigando o produtor a realizar uma colheita antecipada das folhas.

Para evitar a proliferação do *Epitrix* nas lavouras de tabaco, é importante que seja evitado o cultivo de outras plantas hospedeiras próximas à lavoura e que os canteiros das

mudas e os restos da cultura após a colheita sejam destruídos. A rotação de culturas (plantio de outras culturas não hospedeiras no período inverso ao do cultivo do tabaco) também ajuda a combater o *Epitrix* (LEITE *et al.*, 2011).

Outras técnicas também vêm sendo estudadas na tentativa de eliminação do *Epitrix*. Segundo Cuthbertson (2015), a inundação da lavoura pode eliminar grande parte da população da praga que ainda se encontra no solo, uma vez que períodos de seca e solos arenosos favorecem seu crescimento. O uso de nitrogênio também apresentou bons resultados na eliminação do *Epitrix*.

Também é possível realizar o controle do *Epitrix* através da introdução de predadores nas lavouras. De acordo com Leite *et al.* (2011), ao serem introduzidas aranhas em plantações de berinjela no estado de Minas Gerais, observou-se uma diminuição significativa na população do inseto.

A identificação do nível de infestação por *Epitrix* em uma lavoura é muito importante para que se possa definir a gravidade dos danos e decidir qual a melhor forma de controle, ou se as folhas devem ser colhidas antecipadamente. Atualmente, nas lavouras de tabaco da região, esse processo é realizado por técnicos especializados, geralmente contratados pelas fumageiras (que irão comprar as folhas de fumo). Este técnico será responsável por coletar amostras de folhas (Figura 4) e estimar o número de mordidas e o grau de infestação através da análise das perfurações.

Figura 4 - Região de interesse na contagem de mordidas do *Epitrix*.



Fonte: do autor.

O quadrado evidenciado na imagem representa a região de interesse, onde estão localizadas as perfurações. Como as lesões provocadas pelo *Epitrix* geralmente se encontram próximas à veia central da folha, o quadrado é posicionado de forma que uma das laterais fique sobre a veia central (em destaque à direita da Figura 4), e o canto do lado oposto atinja a borda da folha. A área interna do quadrado será a região de interesse do técnico, onde este irá estimar a quantidade de mordidas baseado no número e tamanho das perfurações encontradas.

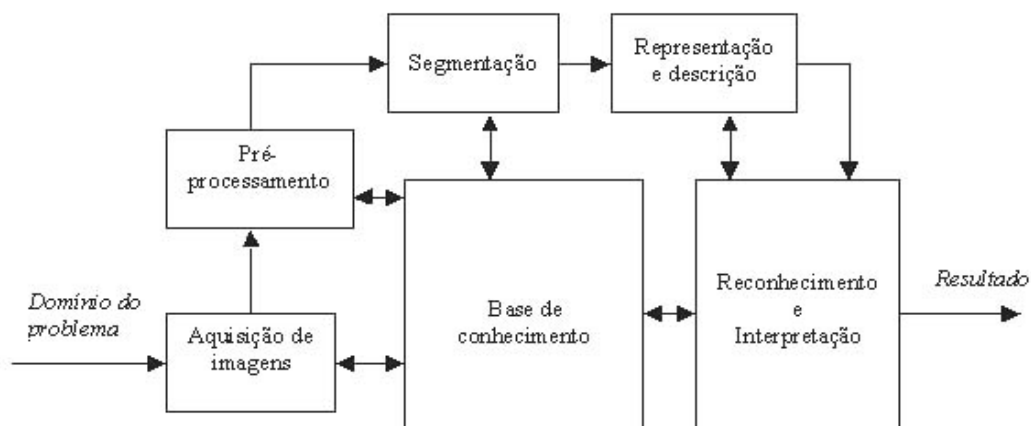
4.3 Processamento de Imagens Digitais

Uma imagem digital pode ser considerada uma matriz que pode ser representada por uma função bidimensional $f(x,y)$, onde x e y se referem às coordenadas espaciais dos elementos da imagem, chamados *pixels*, e o valor de f corresponde ao seu valor naquele ponto, que pode ser sua intensidade de luz, nível de cinza, ou cores reais (GONZALEZ; WOODS, 2000).

O processamento de imagens trata-se da ciência de manipular os *pixels* de imagens. O interesse por estes métodos surgiu a partir de duas áreas de aplicação: o melhoramento de imagens para que a interpretação humana seja mais fácil e a extração de informações de imagens para que sejam tratadas por computadores (GONZALEZ; WOODS, 2000).

Para a realização desse processamento há um amplo número de técnicas que podem ter diversas aplicações. Essas técnicas podem realçar ou distorcer uma imagem, destacar características, criar novas imagens ou ainda restaurar imagens degradadas (CRANE, 1997). Para isso existem algumas etapas importantes (Figura 5) através das quais é possível atingir um resultado a partir de um problema. Todas as etapas serão detalhadas nas seguintes subseções.

Figura 5 - Etapas do processamento de imagens.



Fonte: GONZALEZ; WOODS, 2000.

4.3.1 Aquisição

A primeira etapa no processamento de uma imagem é a aquisição da mesma, ou seja, adquirir uma imagem digital. Uma imagem digital pode ser capturada por um dispositivo ou

sensor que capta um sinal analógico e converte em uma representação digital adequada para o processamento, como por exemplo, a câmera digital, tomógrafo, satélite ou scanner (PEDRINI; SCHWARTZ, 2008).

O tipo de sensor, iluminação da cena, resolução e número de cores são alguns fatores importantes a serem levados em consideração para a aquisição de imagens digitais, pois se as condições não forem boas, as imagens resultantes poderão apresentar imperfeições ou degradações, prejudicando as demais etapas do processamento (PEDRINI; SCHWARTZ, 2008).

4.3.2 Pré-processamento

A etapa seguinte à aquisição da imagem digital é o pré-processamento. O objetivo nesta etapa é melhorar a qualidade da imagem de modo a deixá-la em condições que favoreçam o sucesso das etapas seguintes. Isso é feito através da aplicação de diferentes técnicas, como a atenuação de ruído, correção de contraste ou brilho e suavização ou realce de determinadas propriedades da imagem (GONZALEZ; WOODS, 2000).

4.3.2.1 Modelos de Cores

A cor é uma propriedade importante na análise e no processamento de imagens, pois pode simplificar a identificação e interpretação de objetos pelos seres humanos e também pelo computador. Para descrever como cada cor é constituída, existem diferentes modelos de cores que utilizam diferentes componentes para representá-las. Assim, o modelo de cor a ser utilizado no processamento de uma imagem é uma importante decisão, pois diferentes modelos de cores podem realçar ou atenuar diferentes características da imagem (PEDRINI; SCHWARTZ, 2008).

Os modelos de cores podem ser aditivos ou subtrativos. Em um modelo de cor aditivo, como o RGB e o HSV, a cor é gerada pela combinação de vários comprimentos de onda luminosa, a cor branca é gerada pela soma das cores verde, vermelha e azul, já a cor preta indica ausência de luz. Já em um modelo de cor subtrativo, como o CMYK, a cor preta é formada pela combinação das cores ciano, magenta e amarelo, enquanto a cor branca representa a ausência dessas cores.

O modelo RGB é o mais utilizado em monitores e câmeras digitais e representa as cores utilizando os componentes R (*red*), G (*green*) e B (*blue*), cada um representando, respectivamente, os valores de vermelho, verde e azul para cada pixel da imagem. Porém,

para realçar determinadas partes de uma imagem, muitas vezes estas são convertidas do modelo RGB para outros modelos, como HSV, HSI, $L^*a^*b^*$ ou ainda para escala de cinza.

O modelo HSV é definido pelos parâmetros matiz (H, *hue*), saturação (S, *saturation*) e brilho (V, *value*). Imaginando um círculo com todas as tonalidades de cores, a matiz (ou tonalidade) será um ângulo de 0° a 360° para representar aquela cor. A saturação indica o grau de pureza da matiz, podendo variar de 0 a 1. O brilho também varia de 0, que representa a cor preta, a 1, onde a cor possui intensidade máxima. O modelo HSI funciona de forma semelhante, porém possui o componente correspondente à intensidade (I, *intensity*) ao invés do brilho (PEDRINI; SCHWARTZ, 2008).

O modelo $L^*a^*b^*$ é derivado do modelo XYZ desenvolvido pelo CIE (Comissão Internacional de Iluminação, do francês *Commission Internationale l'Éclairage*) em 1976. Neste modelo, o componente L corresponde à luminância, o componente a^* representa uma relação entre os tons verdes e vermelhos, e o componente b^* representa a relação entre os tons amarelos e azuis (PEDRINI; SCHWARTZ, 2008).

As imagens podem ainda ser representadas em níveis de cinza, com seus *pixels* variando de 0, que representa a cor preta, a 255, que representa a cor branca, com todos os valores intermediários constituindo tons de cinza. Este modelo de cor é muito utilizado para a aplicação de filtros, segmentações e outras operações sobre imagens.

4.3.2.2 Realce de Imagens

As imagens originais muitas vezes não são adequadas para uma aplicação específica por apresentarem ruídos ou ainda destacar características que possam ser confundidas com os objetos de estudo. Com o objetivo de realçar imagens, eliminar ruídos e atenuar certas características, existem diversos filtros que podem ser aplicados.

Estes filtros podem ser aplicados no domínio frequência ou no domínio espacial. Os filtros que atuam no domínio frequência transformam uma imagem original para o domínio frequência, aplicam operações e, em seguida, realizam a operação inversa, convertendo a imagem para sua forma digital. Essa transformação entre domínios é realizada através das técnicas das transformadas, como a de *wavelets*, de Walsh, dos senos e de Fourier. Já os filtros que atuam no domínio espacial utilizam procedimentos que operam diretamente sobre os *pixels* da imagem, geralmente baseando-se no uso de máscaras (ou *kernels*) para modificar a imagem original (GONZALEZ; WOODS, 2000).

4.3.2.3 Filtros Passa-Baixa

Filtros passa-baixa são filtros que deixam passar frequências menores e atenuam frequências maiores do que uma determinada frequência de corte. Convolucionando uma imagem com um filtro passa-baixa é possível gerar um efeito de *blur*, ou seja, deixar as imagens com aspecto borrado, eliminando ruídos e atenuando as suas bordas.

O processo de convolução de uma imagem consiste em posicionar uma máscara de valores (*kernel*) sobre cada *pixel* da imagem e, após a aplicação das operações específicas para cada filtro, o *pixel* na posição central do *kernel* é substituído pelo seu novo valor, originando uma nova imagem. Dentre os filtros mais utilizados estão o *averaging*, gaussiano, mediano e bilateral.

O filtro de *averaging* é o mais simples. Ele consiste em calcular a média dos *pixels* sob a área do *kernel* e substituir o *pixel* central com o novo valor calculado.

O filtro gaussiano é um dos mais utilizados para a remoção de ruídos em imagens, e é obtido através da aplicação do cálculo de $G_0(x,y)$ (eq. 1), onde μ representa o valor médio dos *pixels* no *kernel*, σ é a variação para x e y , “A” representa uma constante de ganho e “e” representa o número de Euler.

$$G_0(x, y) = Ae^{\frac{-(x - \mu_x)^2}{2\sigma_x^2} + \frac{-(y - \mu_y)^2}{2\sigma_y^2}} \quad (1)$$

Um problema do filtro gaussiano é que ele considera os *pixels* próximos, porém não considera se esses *pixels* possuem intensidades semelhantes. Consequentemente, as bordas e contornos também são atenuados. Esse problema pode ser resolvido utilizando o filtro bilateral, que utiliza o mesmo cálculo de pesos do filtro gaussiano, porém considera os *pixels* próximos com intensidades semelhantes para que sejam preservados os contornos da imagem.

Já o filtro mediano consiste em percorrer os *pixels* e substituí-los com a mediana dos valores dos seus *pixels* vizinhos dentro do *kernel*. Diferente dos outros filtros citados anteriormente, que calculam novos valores aos *pixels*, o mediano sempre utilizará valores que já estão em algum ponto da imagem. Este filtro é muito utilizado e efetivo na remoção de ruídos do tipo *salt-and-pepper*.

4.3.2.4 Transformações Morfológicas

A morfologia em processamento de imagens consiste em uma metodologia que auxilia na análise e descrição de objetos. Através de operações simples, é possível eliminar ruídos, realçar objetos de interesse, eliminar pequenos objetos no fundo de uma imagem ou até desacoplar objetos. Tais operações baseadas nas formas da imagem são chamadas transformações morfológicas. As duas operações morfológicas básicas são a erosão e a dilatação. Também há variações destas operações, como a abertura e fechamento (GONZALEZ; WOODS, 2000).

A operação de erosão é realizada aplicando-se um *kernel* sobre uma imagem binária, com *pixels* de valor 0 ou 1. O *pixel* na imagem original só será 1 se todos os *pixels* sob o *kernel* forem 1. Desta forma, os *pixels* próximos aos contornos podem ser descartados dependendo do tamanho do *kernel*, modificando a espessura dos objetos à frente na imagem (*foreground*) e eliminando pequenos objetos dispersos (Figura 6).

Figura 6 - Imagem original (à esquerda) e após aplicação de erosão (à direita).



Fonte: Disponível em: <http://docs.opencv.org/trunk/d9/d61/tutorial_py_morphological_ops.html>.

A dilatação consiste na operação oposta à erosão, sendo aplicada para aumentar a área ou ainda para juntar duas partes de um mesmo objeto em uma imagem. Convolucionando uma imagem, o *pixel* na imagem original será 1 sempre que pelo menos um dos *pixels* sob o *kernel* seja 1, aumentando o tamanho do objeto no *foreground* da imagem (Figura 7).

Figura 7 - Imagem original (à esquerda) e após aplicação de dilatação (à direita).



Fonte: Disponível em: <http://docs.opencv.org/trunk/d9/d61/tutorial_py_morphological_ops.html>.

Nos casos onde se deseja remover ruídos preservando um objeto de interesse, normalmente aplica-se a dilatação após a erosão, pois a erosão remove os ruídos, mas também encolhe os objetos na imagem. Aplicando-se a dilatação logo em seguida, aumenta-se a área do objeto novamente. Essa operação é chamada de abertura (Figura 8).

Figura 8 - Imagem original (à esquerda) e após aplicação de abertura (à direita).



Fonte: Disponível em: <http://docs.opencv.org/trunk/d9/d61/tutorial_py_morphological_ops.html>.

A operação de fechamento segue o processo inverso ao de abertura; primeiro aplica-se a dilatação, seguida da erosão (Figura 9). Essa transformação é útil na eliminação de ruídos, ou “buracos”, dentro dos objetos no *foreground* de uma imagem.

Figura 9 - Imagem original (à esquerda) e após aplicação de fechamento (à direita).



Fonte: Disponível em: <http://docs.opencv.org/trunk/d9/d61/tutorial_py_morphological_ops.html>.

4.3.3 Segmentação

Após o pré-processamento, chega-se à etapa de segmentação. Esta etapa consiste em dividir a imagem em regiões e separar o objeto de interesse para o problema do restante da imagem. A segmentação pode ser descrita como o processo visual de separação entre um objeto (*foreground*) e o fundo da imagem (*background*) (RUSS, 1994).

A segmentação de uma imagem pode ser realizada a partir de duas abordagens que correspondem a duas propriedades básicas de valores de níveis de cinza: descontinuidade e similaridade. Segmentações por descontinuidade são feitas analisando mudanças bruscas nos valores dos *pixels*, como por exemplo, a detecção de linhas, pontos isolados e bordas da imagem. Já a segmentação por similaridade baseia-se em segmentar *pixels* com valores semelhantes, sendo realizada, principalmente, por técnicas de limiarização, crescimento, divisão e fusão de regiões (GONZALEZ; WOODS, 2000).

4.3.3.1 Limiarização

A limiarização, ou *thresholding*, é a forma mais simples de segmentação. O método consiste em determinar um valor base, que será o limiar, e atribuir 0 (preto) a todos os *pixels* com valor abaixo desse limiar, e 255 (branco) a todos os *pixels* com valor acima desse limiar, separando os objetos do *background* da imagem.

A definição do limiar pode ser feita de forma manual ou automática. Defini-lo de forma manual significa utilizar um limiar fixo para toda a imagem. Esta abordagem é a mais simples e de fácil implementação, porém uma imagem pode apresentar diferentes níveis de iluminação em diferentes regiões. Nesses casos, a melhor opção é a utilização de alguma técnica de limiarização automática, que irá definir limiares diferentes para essas regiões.

O algoritmo do triângulo é um método de limiarização automática muito utilizado. O método consiste em traçar uma linha entre o menor e o maior valor de brilho no histograma de

uma imagem. Em seguida, para cada valor no histograma é calculada a distância até a linha, e o nível de cinza da maior distância calculada é utilizado como limiar para a segmentação.


Outro método de segmentação automática famoso é o método de Otsu. Este método é o mais indicado quando temos como entrada uma imagem bimodal, ou seja, uma imagem cujo histograma possui dois picos. O método de Otsu irá iterar por todas as possibilidades de limiares e retornar o *threshold* onde a soma do número de níveis de cinza do *background* e do *foreground* seja mínimo (GREENSTED, 2010).

4.3.3.2 Detecção de Bordas

A detecção de bordas ou contornos é a abordagem mais comum para detecção de discontinuidades e consiste, basicamente, na operação de identificação de mudanças locais significativas nos níveis de cinza da imagem.

As discontinuidades das bordas podem ser detectadas através da aplicação do cálculo de derivadas, pois as bordas são pontos onde a derivada é um ponto máximo. A Figura 10 ilustra de que forma a derivada dos valores de níveis de cinza pode evidenciar as bordas. Tomando como exemplo a imagem à esquerda, que mostra uma faixa clara sobre um fundo escuro, a primeira derivada é positiva na primeira borda, negativa na segunda e nula nas regiões intermediárias. Já a segunda derivada é positiva nas transições associadas ao lado escuro, negativa nas transições associadas ao lado claro e nula para níveis de cinza constantes. Assim, pode-se concluir que utilizando a primeira derivada é possível determinar as bordas de uma imagem, e a partir da segunda derivada é possível dizer ainda se um *pixel* está do lado claro ou escuro (GONZALEZ; WOODS, 2000).


Figura 10 - Detecção de bordas pelo cálculo de derivadas



Fonte: GONZALEZ; WOODS, 2000.

Um operador muito utilizado na diferenciação de imagens é o gradiente (Figura 11). O gradiente é um vetor cuja direção indica os locais onde os níveis de cinza sofrem maior variação. Esse vetor pode ser calculado pelas derivadas parciais de um ponto (x,y) em relação a x e em relação a y . Dessa forma, uma variação rápida no valor calculado em relação a x e lenta em relação a y indica a presença de uma borda vertical, ou vice-versa (PEDRINI; SCHWARTZ, 2008).

Figura 11 - Gradiente em uma borda.



Fonte: PEDRINI; SCHWARTZ, 2000.

Existem diversos operadores baseados em gradiente para a detecção de bordas em imagens, como os operadores Roberts, Prewitt e Sobel. Cada um desses operadores utiliza diferentes *kernels* (Figura 12) para a realização do cálculo dos gradientes, que é obtido através da média dos níveis de cinza dos *pixels* vizinhos. As coordenadas dos *kernels* possuem sinais opostos para que haja um maior contraste nas transições, e a soma dos valores é zero para que a resposta seja também zero quando o nível de cinza da região é constante.

Figura 12 - Kernels utilizados pelos operadores Prewitt, Sobel e Roberts.

$$\begin{aligned}
 \textbf{Prewitt:} \quad M_x &= \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad ; \quad M_y = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix} \\
 \textbf{Sobel:} \quad M_x &= \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad ; \quad M_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \\
 \textbf{Roberts:} \quad M_x &= \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \quad ; \quad M_y = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}
 \end{aligned}$$

Fonte: PEDRINI; SCHWARTZ, 2000.

Cada um destes operadores possui resultados distintos e a opção por um deles dependerá do resultado que se deseja. O operador Roberts, por utilizar um *kernel* 2x2, é bastante sensível a ruídos e pode não ter resultados precisos. Os demais operadores, por utilizarem *kernels* de tamanho 3x3, são muito menos sensíveis a ruído e funcionam de forma semelhante, identificando bordas verticais e horizontais.

Há ainda o operador Laplaciano, que é mais utilizado apenas para indicar de que lado de uma borda se encontra um *pixel*, pois utiliza derivadas de segunda ordem e não detecta a direção das bordas (GONZALEZ; WOODS, 2000).

Pode-se destacar ainda o método de detecção de bordas desenvolvido por Canny (CANNY, 1986). O método também utiliza o cálculo de gradientes, e tem por objetivo obter o máximo de precisão possível, eliminando as bordas detectadas por ruídos, e visando identificar *pixels* localizados no centro das bordas. Para isso, além do cálculo dos gradientes, Canny utiliza ainda um filtro Gaussiano para eliminação de ruídos, e uma limiarização dupla, que consiste em definir um *threshold* para níveis de cinza altos e baixos. Se o gradiente de um *pixel* for maior do que o limiar alto, ele é marcado como um *pixel* de borda forte; se o gradiente for menor do que o limiar alto e maior que limiar baixo, ele é marcado como um *pixel* de borda fraco; e se for menor do que o limiar baixo, o *pixel* não é considerado uma borda.

4.3.3.3 Transformada de Hough

A transformada de Hough é um método desenvolvido inicialmente para a detecção de linhas em imagens, mas que também pode ser aplicado para a identificação de formas geométricas, como círculos e elipses, pois consiste em agrupar pontos da borda que pertençam a um mesmo objeto. Para isso, vários pontos são testados com o objetivo de estabelecer relações entre eles.


O método é muito eficiente na detecção de círculos, sendo capaz de identificar objetos mesmo com a presença de imperfeições na sua borda. Aplicando-se a transformada de Hough para identificar uma circunferência (eq. 2), serão testados vários pontos (h,k) e valores de r (raio) em relação a um determinado ponto (x,y) dentro de um grupo de parâmetros. Se um ponto (h,k) de raio r satisfizer a equação e aparecer com frequência dentro dos parâmetros, existe uma grande chance deste ponto representar o centro de uma circunferência (PEDRINI; SCHWARTZ, 2008).

$$(x - h)^2 + (y - k)^2 = r^2 \quad (2)$$

4.3.3.4 Detecção de *Blobs*

Um *blob* (*Binary Large Object*) consiste de um conjunto de *pixels* conectados em uma imagem, formando um objeto, que compartilham de uma mesma propriedade, como o nível de cinza. Na Figura 13, cada uma das regiões escuras correspondem a um *blob*.

Figura 13 - Imagem contendo vários *blobs*.



Fonte: Disponível em: <<https://www.learnopencv.com/blob-detection-using-opencv-python-c/>>.

O primeiro passo para a detecção de *blobs* em uma imagem é a limiarização, que irá gerar novas imagens, segmentando o que é fundo e o que são objetos dentro da imagem. Após a segmentação, os *pixels* são analisados, e aqueles que compartilham de propriedades semelhantes e se encontram próximos uns dos outros são agrupados. Por fim, para cada uma das regiões identificadas como *blobs* são computados o *pixel* central e o diâmetro do objeto.

4.3.4 Representação e Descrição

A etapa de representação e descrição consiste em transformar os dados iniciais em dados mais adequados para o processamento computacional. Neste processo são extraídas características ou propriedades quantitativas que sejam básicas para discriminação entre classes de objetos (PEDRINI; SCHWARTZ, 2008).

Os dados iniciais a esta etapa são os dados gerados pelos métodos de segmentação discutidos no capítulo anterior, sendo em sua maioria constituídos por informações de *pixels* que façam parte de um contorno ou de uma região da imagem. Algumas vezes esses dados são utilizados diretamente como descritores, como para determinar a textura de uma região, porém a prática mais comum é a de compactar esses dados em representações ou realizar o cálculo de descritores, tais como diâmetro, curvatura e área.

Dependendo do resultado que deseja-se obter, a representação dos dados pode se dar por fronteira ou por região. A representação por fronteiras se concentra nas características externas, como bordas e cantos. Já a representação por região é mais adequada quando o que

interessa são propriedades internas, como forma, textura, cor ou área (GONZALEZ; WOODS, 2000).

4.3.5 Reconhecimento e Interpretação

Por fim, há a etapa de reconhecimento e interpretação, que consiste na compreensão e descrição final do objeto estudado. O reconhecimento consiste no processo de atribuir rótulos aos objetos identificados na imagem, enquanto que a interpretação consiste em atribuir significado aos objetos reconhecidos (GONZALEZ; WOODS, 2000).

A etapa de reconhecimento geralmente é realizada através da classificação de padrões. Que visa mapear as propriedades extraídas das amostras e agrupá-las em classes de objetos que possuam essas mesmas propriedades, baseando-se, para isto, em uma base de conhecimento construída previamente.

Dentre os métodos de classificação mais comumente utilizados podemos citar as árvores de decisão, lógica fuzzy, máquina de vetor de suporte (SVM), classificadores bayesianos e redes neurais.

Essa classificação pode ocorrer de forma supervisionada ou não-supervisionada. Os classificadores supervisionados classificam os objetos dentre um determinado conjunto de classes conhecidas, passando primeiramente por um processo de treinamento onde são criadas regras de classificação para cada classe. Já classificadores não-supervisionados são capazes de definir classes de objetos e não necessitam de treinamento.

5 TRABALHOS RELACIONADOS

Neste capítulo serão apresentados e descritos alguns trabalhos relacionados que utilizam o processamento de imagens para solucionar problemas semelhantes ao deste trabalho para, através do estudo das técnicas utilizadas e de seus resultados, se consiga definir quais abordagens e métodos podem trazer bons resultados para a solução proposta neste trabalho.

5.1 *A new automatic method for disease symptom segmentation in digital photographs of plant leaves*

O trabalho desenvolvido por (BARBEDO, 2016) apresenta um método para realizar a identificação de sintomas de patologias em folhas de plantas de uma forma geral, isto é, o trabalho não visou à aplicação para tipos específicos de planta e sintoma. O objetivo proposto pelo autor foi o de aplicar um método simples, que apenas utiliza-se manipulações de canais de cores e operações booleanas para fazer essa identificação.

O modelo de cores utilizado pelo autor foi o RGB, não sendo necessário nenhum tipo de conversão. Também não foi aplicada nenhuma técnica de pré-processamento, como eliminação de ruídos ou realce de contraste, pois sua aplicação não teve impactos positivos nos resultados.

O primeiro passo para o método de segmentação proposto é o cálculo dos fatores $r1$ (eq. 3) e $r2$ (eq. 4), onde “R”, “G” e “B” representam, respectivamente, os valores de vermelho (*red*), verde (*green*) e azul (*blue*) de cada *pixel* e “E” trata-se de um número muito pequeno para evitar divisões por zero.

$$r_1 = R / (G + \epsilon) \quad (3)$$

$$r_2 = B / (G + \epsilon) \quad (4)$$

Os valores obtidos para $r1$ e $r2$ medem, respectivamente, o desvio de cada *pixel* de um tom verde para um tom mais vermelho ou azul, ou seja, quanto menor os seus valores, mais verde será o *pixel* e, em teoria, mais saudável é aquela parte da folha.

Em seguida são geradas quatro máscaras (M1, M2, M3 e M4) seguindo as seguintes regras, com x e y sendo coordenadas de *pixels*:


- $M1(x,y) = 1$ se $r1(x,y) > 1$, senão 0;
- $M2(x,y) = 1$ se $r2(x,y) > 1$, senão 0;
- $M3(x,y) = 1$ se $r1(x,y) > 0.9$, senão 0;

- $M4(x,y) = 1$ se $r2(x,y) > 0,67$, senão 0.

No passo seguinte essas máscaras são unificadas em outras duas, estas são: $Ma = M1 \text{ OR } M2$ (operação lógica *OU*) e $Mb = M3 \text{ AND } M4$ (operação lógica *E*). O intuito por trás dessas máscaras é destacar as regiões menos verdes, onde provavelmente as folhas estarão sendo alvo de algum distúrbio, sendo a máscara Ma é mais apropriada para detectar sintomas escuros ou amarelados, enquanto que a máscara Mb detecta melhor sintomas claros. Mudando os limiares utilizados nas máscaras acima é possível mudar as fronteiras do que é considerado saudável ou não.

Uma máscara final M ainda é gerada por $Ma \text{ OR } Mb$. Nesta última, todos os *pixels* identificados como danificados terão valor 1 e os demais 0, de forma que multiplicando-a pela imagem original, apenas os *pixels* com algum sintoma devem aparecer e os saudáveis serão pretos. A Figura 14 mostra um exemplo desse processo de segmentação, contendo a imagem original, mas máscaras Ma , Mb e M e o resultado final da segmentação.

Figura 14 - Resultado para o método de segmentação.



Fonte: BARBEDO, 2016.

Para testar sua eficiência, os resultados das imagens segmentadas pelo método proposto foram comparados com imagens manualmente segmentadas por técnicos e também com outros métodos de segmentação: utilização de um limiar de segmentação fixa, método de Otsu e os métodos propostos por Camargo e Smith (2009) e por Huang (2007).

Para os 9 sintomas amostrados e testados, a taxa de falsos positivos e negativos para o algoritmo proposto variou de 0.5% a 7%, enquanto que para todos os outros métodos comparados a variação foi maior, variando entre 1.2% e 18.9%. Os resultados podem ser vistos na Figura 15, onde as colunas FP, FN e DP correspondem, respectivamente, ao número à porcentagem de falsos positivos, falsos negativos e à proporção de *pixels* danificados.

Figura 15 - Comparação dos resultados do método proposto


	Proposed			Fixed Thresholding			Otsu's Thresholding			Camargo and Smith (2009)			Huang (2007)			Assess		
Symptom Type	FP	FN	DP	FP	FN	DP	FP	FN	DP	FP	FN	DP	FP	FN	DP	FP	FN	DP
Homogeneous Dark	0.5	5.3	93.0	3.9	8.2	90.5	2.8	6.9	92.0	1.2	7.0	94.1	1.9	7.8	90.1	0.8	3.5	*
Homogeneous Bright	1.2	6.1	92.9	1.3	11.5	91.1	3.5	8.4	90.7	1.5	7.7	90.8	2.5	7.0	89.9	0.9	4.1	*
Heterogeneous	1.8	5.9	87.3	18.9	12.5	78.3	17.1	13.4	74.9	15.4	12.9	88.0	14.9	17.3	74.3	1.5	6.9	*
Powdery White	5.2	5.2	61.5	5.3	6.1	65.0	5.1	5.5	70.2	8.9	6.8	59.9	7.8	7.6	60.8	3.8	5.2	*
Powdery Dark	0.3	4.7	98.2	2.3	7.0	95.9	2.5	5.8	96.4	2.0	5.4	97.7	2.5	5.7	96.0	0.9	2.4	*
Small Dark	2.0	6.6	59.1	4.0	8.5	62.3	3.3	7.5	61.1	4.0	8.8	60.1	4.7	8.3	55.0	1.1	2.1	*
Small Bright	6.0	6.1	70.7	10.8	9.4	63.3	10.8	8.8	65.4	9.8	8.8	59.1	8.4	9.7	58.2	3.9	5.8	*
Color Changing	3.3	7.0	80.0	6.1	6.0	82.3	5.9	6.1	82.5	4.4	5.5	85.1	4.4	7.8	81.3	1.8	1.9	*
Mosaic	0.9	4.9	89.8	2.3	4.5	88.5	2.8	4.3	89.2	2.5	4.8	87.2	3.1	5.4	86.2	1.2	3.2	*
Mean Value	2.4	5.8	81.4	6.1	8.2	79.7	6.0	7.4	80.3	5.5	7.5	80.2	5.6	8.5	76.9	1.8	3.9	*

Fonte: BARBEDO, 2016.

De um modo geral, o método proposto mostrou-se eficiente, uma vez que apresentou pouca variação dependendo dos sintomas, onde outros métodos apresentaram grande variação no número de *pixels* identificados como falsos positivos e negativos. O autor cita como um dos maiores problemas a aquisição das imagens, pois as condições em que são adquiridas podem influenciar os resultados do método de segmentação.

5.2 An image-processing based algorithm to automatically identify plant disease visual symptoms

O algoritmo proposto por Camargo e Smith (2009), assim como o trabalho descrito anteriormente, consiste em um método baseado em processamento de imagem que identifica sintomas visuais de doenças em plantas, atacando o problema de um ponto de vista generalista, ou seja, sem focar em nenhum tipo de planta e sintoma específicos, como demonstra a Figura 16.

Figura 16 – Resultado da segmentação realizada pelo autor.

Fonte: CAMARGO; SMITH, 2009.

O primeiro processo, que consiste na transformação de cores, tem por objetivo enfatizar as regiões da imagem onde haja sintomas de doenças, aumentando a assertividade do algoritmo. Em um primeiro momento, as imagens em RGB foram transformadas para os canais de cores HSV e $l1i2i3$. Destes, foram usados apenas os canais H e I3, por apresentarem melhor ênfase nas regiões de interesse.

Após as transformações de cores, o algoritmo realiza um pré-processamento das imagens para suavizar as variações de intensidade e tornar a segmentação mais eficiente. Para isso, as imagens são suavizadas utilizando o filtro Gaussiano, que suaviza as altas frequências da imagem e gera um efeito de *blur*.

A próxima etapa do algoritmo é a segmentação do objeto de interesse do restante da imagem. Essa separação é feita usando um limiar calculado de acordo o histograma de frequências da imagem. O histograma é dividido em regiões, e os mínimos localizados entre duas vizinhanças maiores de cada região indicam mudanças bruscas de intensidade e são usados como limiar para a segmentação entre áreas neutras e áreas com presença de sintomas. As partes da imagem que não são de interesse, ou seja, tudo que não for identificado como sintoma de algum distúrbio na imagem da planta, é descartado.

Para a validação do método, as regiões segmentadas pelo processamento de imagem foram comparadas com segmentações feitas manualmente, utilizando a expertise humana. O algoritmo teve êxito em identificar regiões que apresentam sintomas de doenças em plantas, porém a taxa de acerto do algoritmo teve uma grande variação. Assim como houve imagens com 98% de acerto, outras tiveram aproximadamente 50%, como mostra a Figura 17, contendo os resultados da segmentação de 20 imagens.

Figura 17 - Resultados da segmentação de 20 imagens.

Image	Matching, %	Misclassified, %	av	Diseased pixels, %
1	95.6	4.6	91	3.1
2	72.4	11.7	60.7	12.3
3	67.2	8.1	59.1	21.6
4	96.5	13.9	82.6	7.3
5	42	18.6	23.4	31.4
6	56.3	15.1	41.2	34.1
7	48.7	35.5	13.2	68.8
8	59.3	20.6	38.7	46.2
9	85	4.7	80.3	6.2
10	85.2	11	74.2	7.9
11	65.6	15.2	50.4	41.6
12	61.2	15.3	45.9	24
13	64.4	24.9	39.5	20.4
14	77.6	10	67.6	40.9
15	86.5	6.2	80.3	32.6
16	85.9	4.5	81.4	12.1
17	94.4	5.7	88.7	4.6
18	95.9	2.2	93.7	7.4
19	98.3	3.8	94.5	11.1
20	93	6.4	86.6	10.5

Fonte: CAMARGO; SMITH, 2009.

Essa variação deve-se principalmente pela variação de condições das imagens. Outra dificuldade encontrada foi a existência de pontos com reflexos de luz na imagem, que podem acabar sendo segmentados como regiões de interesse devido à variação de intensidade, porém não são regiões que apresentam sintomas de doença na planta, o que acaba diminuindo a taxa de acerto.

Como sugestão de trabalho futuro, os autores sugerem a aplicação de um método de classificação dos *pixels* segmentados para que, com isso, se consiga treinar um sistema inteligente e extrair parâmetros das imagens, classificando-as de acordo com suas propriedades.


5.3 Leaf disease severity measurement using image processing

Desenvolvido por (PATIL; BODHE, 2011), este trabalho objetiva realizar a medição da severidade dos sintomas causados por fungos na cana-de-açúcar, caracterizados pelo aparecimento de pontos marrons nas folhas da planta.

As imagens utilizadas no trabalho foram adquiridas em ambiente controlado com fundo branco. Assim, para segmentar a região da folha, a imagem é convertida para escala de cinza e binarizada, distinguindo o fundo e o objeto (planta).

Para a segmentação da região doente, a imagem é transformada para o canal de cores HSI, que realça mais as características de brilho na imagem. O limiar para segmentação é obtido através do método de limiarização triangular, onde o *threshold* é obtido a partir do histograma de intensidades da imagem. A Figura 18 demonstra os resultados obtidos com a segmentação.

Figura 18 - Demonstração do resultado da segmentação.



Fonte: PATIL; BODHE, 2011.

Após o processo de segmentação, é calculada a área segmentada, que corresponde à área da folha que apresenta sintomas da patologia. A severidade da doença é então classificada de acordo com o percentual da folha que foi infectada. As cinco categorias utilizadas na classificação são apresentadas na Figura 19.

Figura 19 - Categorias para a classificação da severidade da infestação.


Category	Severity
0	Apparently infected
1	0 – 25% leaf Area infected
2	26 – 50% leaf Area infected
3	51 – 75% leaf Area infected
4	>75% leaf Area infected

Fonte: PATIL; BODHE, 2011.

O método foi testado comparando seus resultados com o resultado de segmentações realizadas manualmente e alcançou um índice médio de 98,6% de acerto, mostrando ser eficiente para o problema abordado. O único problema citado pelo autor são as variações nos sintomas do distúrbio estudado dependendo do estágio de infestação, podendo prejudicar a assertividade do método.

5.4 A new colour vision system to quantify automatically foliar discoloration caused by insect pests feeding

Este trabalho foi desenvolvido por (CLEMENT *et al.*, 2015) e visa identificar automaticamente o branqueamento de folhas de sicômoro devido à alimentação de insetos utilizando um ambiente controlado para a aquisição das imagens (Figura 20).

Figura 20 - Resultado da segmentação

Fonte: (CLEMENT *et al.*, 2015)

Primeiramente as folhas são segmentadas do background das imagens. Para isso, o modelo de cores é convertido de RGB para $L^*a^*b^*$ e é aplicado o método de binarização de Otsu apenas no componente b^* da imagem.

Em seguida, nas partes correspondentes à folha, é calculado um histograma de clorofila, isto é, do quão verde é cada *pixel*. Este cálculo é realizado através de divisão do valor de verde pelo valor de vermelho de um *pixel* (G/R). O histograma é então normalizado entre 0 e 1 e, por fim, é aplicado o método de segmentação de Otsu de modo a encontrar um limiar que separa a imagem em áreas saudáveis e esbranquiçadas.

O método foi testado com segmentações feitas manualmente por técnicos especializados, onde foi comparada a área classificada como saudável e danificada em ambos os métodos. A especificidade e sensibilidade calculados para o método foram de aproximadamente 85% e 95%, respectivamente. A especificidade representa a taxa de verdadeiros negativos, sendo obtida pela divisão do número de *pixels* identificados corretamente como saudáveis pelo total de *pixels* saudáveis. Já a sensibilidade representa a taxa de verdadeiros positivos, sendo calculada pela divisão do número de *pixels* identificados corretamente como saudáveis pelo total de *pixels* saudáveis.


5.5 Grading method of leaf spot disease based on image processing

O trabalho desenvolvido por (WEIZHENG *et al.*, 2008) apresenta outro método utilizando processamento de imagem para identificar pontos que apresentem sintomas de algum distúrbio em folhas de plantas de um modo geral.

O método consiste em, primeiramente, transformar a imagem para escala de cinza e segmentar a folha do fundo da imagem utilizando o método de Otsu.

Para segmentar a área da lesão, a imagem é transformada para o sistema de cores HSI. Utilizando o método de detecção de contornos de Sobel, são identificadas as veias da folha e as regiões com presença de sintomas. A operação morfológica de abertura foi aplicada para eliminar as veias e outras regiões indesejadas. Regiões com bordas fechadas são então preenchidas, gerando a segmentação dos pontos e regiões onde há presença de sintomas de patologias nas folhas, como mostrado na Figura 21.

Figura 21 - Exemplo de imagem segmentada.



Fonte: WEIZHENG *et al.*, 2008.

Todo o processo de segmentação foi realizado no canal H da imagem no modelo HSI, por já destacar mais as regiões lesionadas nas folhas. O método se difere dos demais apresentados anteriormente por não utilizar nenhum método de limiarização para a segmentação das áreas lesionadas, utilizando, ao invés disso, a detecção de contornos para a identificação de objetos fechados.

O ponto fraco deste estudo fica por conta dos resultados, pois o autor não apresenta nenhum tipo de comparação com outros métodos ou qualquer métrica para um índice de assertividade.

5.6 Considerações

Os trabalhos descritos nas seções acima foram selecionados através da busca por artigos e publicações que utilizam o processamento de imagem como solução para a identificação de patologias e infestações que provocam sintomas em folhas de plantas. A Tabela 2 apresenta uma comparação entre os trabalhos estudados, diferenciando-os quanto ao modelo de cor, técnicas de pré-processamento e o método de segmentação utilizados.

Tabela 2 - Comparativo entre os trabalhos selecionados.

Nome	Modelo de cor	Pré-processamento	Segmentação
<i>A new automatic method for disease symptom segmentation in digital photographs of plant leaves</i>	RGB	-	Limiarização utilizando manipulação de canais de cores e operações booleanas.
<i>An image-processing based algorithm to automatically identify plant disease visual symptoms</i>	HSV e $i1i2i3$	Filtro gaussiano	Limiarização baseada nos mínimos localizados entre duas intensidades maiores dentro de regiões do histograma.
<i>Leaf disease severity measurement using image processing</i>	HSI	-	Limiarização triangular.
<i>A new colour vision system to quantify automatically foliar discoloration caused by insect pests feeding</i>	$L^*a^*b^*$	Cálculo do nível de clorofila de cada <i>pixel</i> e normalização entre 0 e 1.	Método de Otsu.
<i>Grading method of leaf spot disease based on image processing</i>	HSI	Operação morfológica de abertura	Detecção de objetos fechados pelo método de Sobel para detecção de contornos.

Fonte: do Autor.

Nota-se que todos os trabalhos seguem linhas diferentes quanto às técnicas utilizadas no pré-processamento e na segmentação de imagens. Portanto, para o desenvolvimento de uma aplicação para o processamento de imagens de plantas, será necessária a realização de vários testes para determinar o que é mais adequado.

Quanto ao modelo de cor, dois dos cinco trabalhos analisados utilizam o modelo HSI e apresentaram bons resultados visuais na segmentação, indicando que este modelo pode ser uma boa opção para o desenvolvimento do trabalho proposto.

Mesmo não sendo aplicada nenhuma técnica em alguns dos trabalhos, a etapa de pré-processamento pode ser muito importante no processamento de imagens de folhas de plantas, uma vez que essas apresentam ramificações e outras marcas que podem representar ruídos e resultarem em erros de segmentação.

Através das pesquisas realizadas e da análise destes trabalhos, percebe-se que o tratamento de imagens é um método já muito utilizado e que é capaz de apresentar resultados muito confiáveis no processamento de imagens de plantas. Porém, muitos destes trabalhos não tratam de um tipo específico de planta ou visam segmentar um tipo de sintoma específico.

Poucos trabalhos realizam o processamento de imagens de folhas de tabaco, e a maior parte destes trabalha com o tabaco em seu estado pronto para comercialização, após o processo de cura. Dentre estes trabalhos pode-se citar o realizado por Zhang; Zhang (2011), que realiza a classificação do tabaco quanto ao seu tipo através da análise de imagens de folhas após o processo de cura.

Diversos trabalhos também utilizam métodos de classificação das áreas segmentadas para identifica-las como regiões saudáveis ou danificadas das plantas. Alguns destes métodos que pode-se destacar são o uso de redes neurais, aplicado por Abdullah *et al.* (2007) e Huang (2007), lógica *fuzzy*, utilizada por Azmi; Isa (2013), SVM (*Support Vector Machine*), utilizado por Barbedo; Koenigkan; Santos (2016), dentre outros métodos de classificação baseados na seleção de características, como os desenvolvidos por Kruse *et al.* (2014) e Phadikar; Das (2013).

Como o trabalho proposto não tem por objetivo a utilização de um método de classificação, os trabalhos relacionados descritos neste capítulo foram escolhidos por focarem na etapa de segmentação das imagens, apresentando diferentes métodos que podem servir de ponto de partida para o desenvolvimento do trabalho proposto.

6 TRABALHO PROPOSTO

Neste capítulo será descrito o sistema proposto, que visa identificar a infestação por *Epitrix* em folhas de tabaco através do processamento de imagens, mostrando como os aspectos teóricos discutidos anteriormente foram aplicados para o seu desenvolvimento.


6.1 Visão geral

Como entrada para o sistema foi utilizado um conjunto de imagens obtidas em campo, isto é, imagens capturadas por técnicos que realizam a análise de infestação por *Epitrix* nas próprias lavouras de tabaco, seguindo o procedimento descrito na seção 4.2.

O sistema foi desenvolvido na linguagem C++ e para a implementação das etapas do processamento de imagens foi utilizada a biblioteca OpenCV (Open Source Computer Vision Library). A biblioteca é de código aberto e tem por objetivo proporcionar uma infraestrutura comum para acelerar o desenvolvimento de aplicações que envolvem visão computacional, oferecendo mais de 2500 algoritmos otimizados já implementados (OPENCV, 2017).

A figura 22 mostra as técnicas utilizadas em cada uma das etapas básicas do processamento de imagens digitais, que compreendem as etapas de aquisição, pré-processamento, segmentação, representação e descrição e reconhecimento e interpretação, como descrito na seção 4.3.

Figura 22 - Técnicas utilizadas em cada etapa do processamento de imagens.



Fonte: Autor.

Das técnicas mencionadas na fundamentação teórica, a única descartada foi a segmentação através da detecção de círculos com a transformada de Hough. O método foi utilizado em testes na fase inicial do desenvolvimento porém não obteve bons resultados por não conseguir identificar corretamente formas arredondadas porém com muitas imperfeições. Por este motivo, a técnica foi descartada.

Na etapa de segmentação foram implementadas e testadas 4 metodologias distintas para a detecção das áreas com mordidas do *Epitrix* nas imagens. Estas metodologias foram: a

limiarização binária utilizando um limiar fixo, a limiarização binária com limiar calculado a partir do valor máximo e mínimo dos pixels, a segmentação através do método desenvolvido por Barbedo (2016), apresentado na seção 5.1, e a segmentação utilizando o canal H do modelo de cores HSI. Daqui em diante, estas metodologias serão chamadas de métodos de segmentação 1, 2, 3 e 4, respectivamente.

Nos subcapítulos seguintes cada uma das cinco etapas e as técnicas utilizadas em cada uma serão explicadas com mais detalhes.

6.2 Aquisição

As imagens utilizadas para validar o sistema foram cedidas pelo co-orientador deste trabalho, Professor Andreas Koehler, e foram obtidas em lavouras de tabaco seguindo o procedimento já citado anteriormente, que consiste no posicionamento de um quadrado sobre uma região específica da folha de modo a analisar somente a área interna do mesmo.

As imagens foram obtidas com uma câmera digital e não seguiram um padrão de resolução, iluminação ou *background*, o que dificultou as demais etapas do seu processamento. Para suavizar o impacto negativo da falta de padronização, todas as imagens foram tratadas antes de serem utilizadas para alimentar o sistema. Este tratamento consistiu em segmentar a área de interesse, isto é, a região interna do quadrado, e deixá-las com o mesmo número de pixels. Todas as imagens foram modificadas de modo a ficarem com uma resolução de 1920x1920 pixels. Para isto, foi utilizada a função *resize* do *OpenCV*. A figura 23 demonstra o resultado deste tratamento em uma das imagens.

Figura 23 - À esquerda a imagem original e a direita após o tratamento inicial para o processamento.



Fonte: Autor.

No total foram cedidas 69 imagens. Destas, 2 foram eliminadas por apresentarem condições ruins tanto para o processamento quanto para a análise manual. Foi utilizado então um conjunto de 67 imagens para a validação do sistema.

6.3 Pré-processamento

No pré-processamento, as técnicas utilizadas foram diferentes dependendo do método de segmentação. Para os métodos 1 e 2, inicialmente as imagens foram convertidas para escala de cinza, o que foi feito através da função *cvtColor* do *OpenCV*, que recebe como entrada uma imagem colorida e retorna uma nova imagem com um único canal cujo valor de cada pixel varia de 0 a 255, como na figura 24.

Figura 24 - Imagem para escala de cinza.



Fonte: Autor.

Já no método 4, foi utilizado o modelo de cores HSI. O *OpenCV* não disponibiliza de nenhuma função para a conversão para este modelo de cores, então esta conversão foi feita através de uma função desenvolvida pelo autor. A função calcula o valor de cada canal para cada pixel de acordo com a regra mostrada na figura 25.


Figura 25 - Regra para conversão RGB para HSI.

$$\begin{aligned}
 I &= \frac{1}{3}(R + G + B) \\
 S &= 1 - \frac{3}{(R + G + B)}[\min(R, G, B)] \\
 \text{if } B \leq G & \\
 H &= \cos^{-1} \left[\frac{\frac{1}{2}[(R - G) + (R - B)]}{\sqrt{(R - G)^2 + (R - B)(G - B)}} \right] \\
 \text{else, } H &= 360 - H
 \end{aligned}$$

Fonte: Disponível em: <<http://answers.opencv.org/question/62446/conversion-from-rgb-to-hsi/>>

Em todas imagens foi aplicado o filtro Gaussiano através da função *GaussianBlur* do *OpenCV*, com um *kernel* de 15 pixels de largura e altura. Utilizando essa função, é aplicado um efeito de *blur* para as imagens visando suavizá-la e diminuir a presença de ruídos para a etapa seguinte de segmentação. Um exemplo de aplicação pode ser conferido na figura 26.


Figura 26 - Antes e depois da aplicação do filtro Gaussiano.



Fonte: Autor.

Também foi utilizado em todas as imagens a aplicação da operação morfológica de abertura, com o objetivo de eliminar áreas muito pequenas que tenham sido segmentadas, como demonstra a figura 27, que à direita apresenta alguns pontos removidos dentro da área demarcada pelo círculo.

Figura 27 – Antes e depois da aplicação da operação de abertura.



Fonte: Autor.

6.4 Segmentação

Como já mencionado anteriormente, foram testados quatro métodos diferentes de segmentação. Em seguida será descrito o desenvolvimento e as características de cada um deles.

6.4.1 Método Um: Limiarização binária com limiar fixo

Consiste na limiarização simples, onde os pixels com valor abaixo do limiar são setados para 0 (preto) e os pixels com valor superior ao limiar são setados para 255 (branco).

Para a implementação do método, utilizou-se a função *threshold* do *OpenCV*. Este método recebe como parâmetros a imagem a ser segmentada, o limiar, o valor que será atribuído aos pixels segmentados (255) e o método de segmentação a ser utilizado, que neste caso deve ser a constante *CV_THRESH_BINARY*, que representa o método de limiarização binária no *OpenCV*.

Com base em testes realizados, o limiar que obteve melhor resultados foi de 220. Assim, apenas os pixels mais claros, com valor acima de 220, foram segmentados pela função, e estes pontos geralmente representam as regiões onde há perfurações causadas pelo *Epitrix* uma vez que o background das imagens geralmente é claro. A Figura 28 ilustra a segmentação de uma imagem por este método.

Figura 28 - Limiarização binária com limiar fixo.



Fonte: Autor.

6.4.2 Método Dois: Limiarização binária utilizando mínimo e máximo

Funciona da mesma forma que o método anterior, utilizando a mesma função para sua implementação, porém com o limiar variável. Aqui o limiar é calculado com base no mínimo e máximo da imagem. O valor mínimo é o pixel de menor valor da imagem (mais escuro), enquanto que o máximo é o pixel de maior valor (mais claro). Estes valores podem ser obtidos percorrendo os pixels da imagem ou ainda utilizando a função *minMaxLoc*, que retorna os valores e as posições dos pixels de valor mínimo e máximo dentro da imagem.

Obtidos os valores mínimo e máximo, o limiar utilizado na segmentação será a diferença entre eles, ou seja, será o valor máximo subtraído do valor mínimo. Desta forma, o

limiar não será sempre o mesmo e irá depender de características da própria imagem. A figura 29 demonstra o resultado da segmentação para a mesma amostra da imagem anterior, utilizando limiar de 235.

Figura 29 - Limiarização binária utilizando mínimo e máximo.



Fonte: Autor.

6.4.3 Método Três: Segmentação utilizando o método proposto por Barbedo (2016)

Pelo método estudo nos trabalho relacionados ter apresentado bons resultados na detecção de sintomas em plantas de um modo geral, o mesmo método foi desenvolvido e adaptado para o trabalho proposto.

Como explicado na seção 5.1, o método consiste no cálculo dos coeficientes $r1$ (eq. 3) e $r2$ (eq. 4), que medem o desvio de cada pixel do tom verde para um tom mais vermelho ou azul, respectivamente. Em seguida são geradas quatro máscaras (M1, M2, M3 e M4) cada uma respeitando uma condição. Os valores originais do trabalho relacionado para a obtenção destas máscaras foram alterados para se adequarem para o trabalho proposto e foram determinados através da experimentação. As condições utilizadas foram:

- $M1(x,y) = 1$ se $r1(x,y) > 1$, senão 0;
- $M2(x,y) = 1$ se $r2(x,y) > 0,8$, senão 0;
- $M3(x,y) = 1$ se $r1(x,y) > 0.9$, senão 0;
- $M4(x,y) = 1$ se $r2(x,y) > 0,7$, senão 0.

Em seguida são obtidas mais duas máscaras:

- $Ma = M1 \text{ OR } M2$
- $Mb = M3 \text{ AND } M4$

Destas, Ma tem o intuito de destacar regiões escuras e amareladas, e Mb destaca regiões claras na imagem. Como no trabalho proposto o que mais interessa são as regiões

claras com a presença de perfurações na folha, apenas a máscara Mb foi utilizada para a segmentação. Como pode ser visto na figura 30, aplicando-se a máscara sobre os *pixels* da imagem, os pixels mais claros da imagem permanecem e os demais são setados para 0.

Figura 30 - Regiões claras destacadas pelo método de Barbedo (2016).



Fonte: Autor.


A etapa final do método proposto por Barbedo (2016) não foi considerado, que seria a união das duas máscaras, destacando todas regiões com presença de sintomas, tanto escuras quanto claras.

6.4.4 Método Quatro: Segmentação utilizando canal H do modelo HSI

A decisão pela utilização do modelo de cores HSI veio de testes realizados com outros modelos e do trabalho desenvolvido por Weizheng et al. (2008), que utilizou o canal H do modelo HSI para aplicar seu método de segmentação.

A figura 31 mostra uma imagem convertida para o modelo HSI. Como pode-se perceber, o modelo destaca regiões com mais intensidade na imagem, que no caso do exemplo são as veias principais da folha e alguns pontos internos. estes pontos internos são perfurações causadas pelo *Epitrix* e que deseja-se segmentar do restante da imagem.

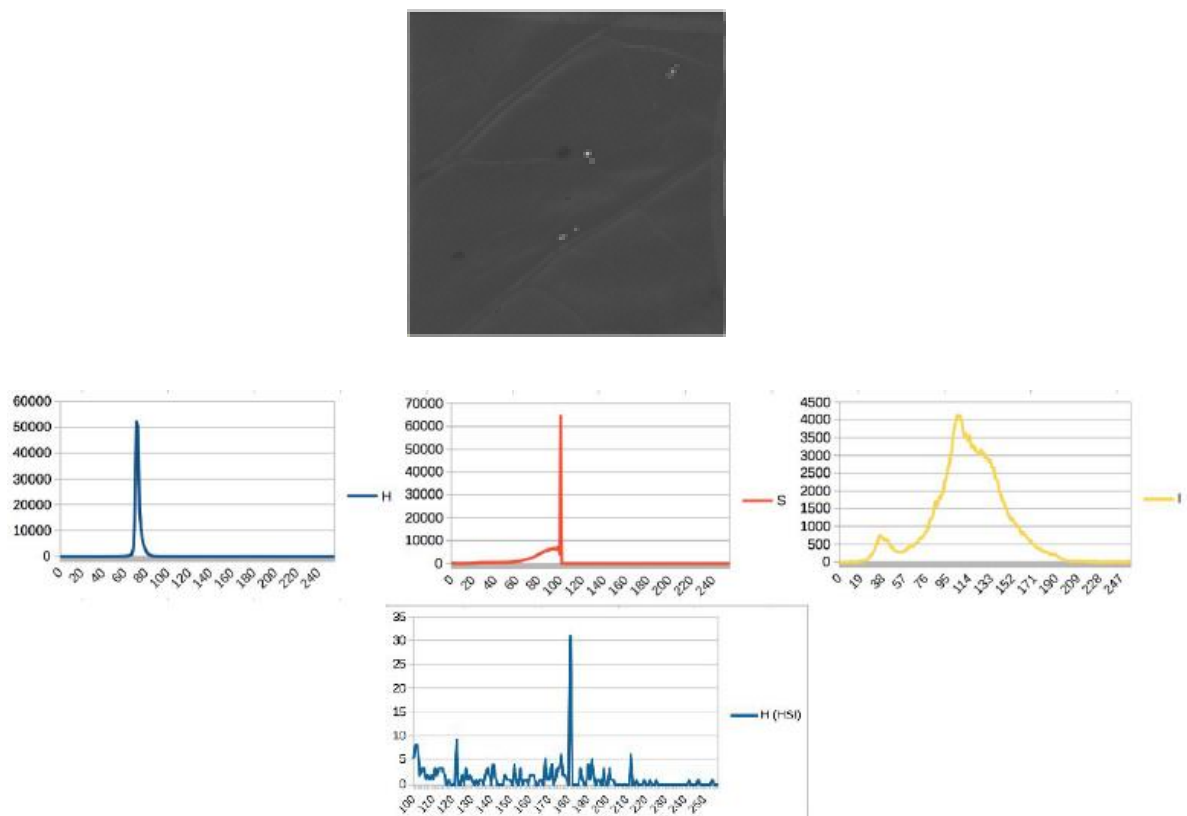
Figura 31 - Imagem convertida para o modelo HSI.



Fonte: Autor.

Ao analisar em separado o canal H da imagem no modelo HSI, nota-se uma grande homogeneidade nos valores dos pixels da imagem, tendo uma grande quantidade de pixels nos valores intermediários de níveis de cinza, e poucas regiões de pixels claros bem destacados, que são as regiões de interesse para o trabalho. Essa característica pode ser vista na figura 32, que demonstra o histograma dos canais HSI de uma imagem e, abaixo, o seu histograma apenas do canal H dos *pixels* com valor 100 a 255.

Figura 32 - Canal H e seu histograma.



Fonte: Autor.

Na prática, isso se reflete em uma representação mais precisa das regiões de tonalidades mais próximas à cor branca no modelo HSI, pois se aplicando qualquer limiar acima do valor onde se encontram a maioria dos valores intermediários dos pixels, já será possível segmentar as regiões mais claras.

A conversão das imagens para o modelo HSI foi feita calculando-se o valor de cada pixel baseado nos valor de RGB da imagem original, conforme o método citado no Pré-processamento. A separação dos canais é feita pela função *split* do *OpenCV*. A função *split* retorna um vetor de 3 posições onde cada posição representa um canal. Para obter-se o canal H, basta retirar a imagem na posição 0 (primeira posição) deste vetor

6.5 Representação e Descrição

Para transformar a segmentação realizada anteriormente em dados relevantes para a análise das regiões de infestação identificadas pelo *software*, foi realizada a detecção de *Blobs* nas imagens segmentadas, que consiste na detecção de objetos fechados, como descrito na seção 4.3.3.4.

Essa detecção foi implementada utilizando a classe *SimpleBlobDetector* presente no *OpenCV*, que disponibiliza a configuração dos parâmetros e o método para a detecção. A classe permite filtrar os objetos detectados pela sua área, circularidade, convexidade e inércia. No trabalho proposto os únicos filtros utilizados foram de área e circularidade.

Para descartar pequenos ruídos e regiões muito pequenas, que geralmente resultavam em classificações incorretas, foi utilizado um filtro de área com valor mínimo de 15 pixels, descartando objetos com área menor.

E, como a maioria das perfurações causadas pelo *Epitrix* apresentam formato circular, foi utilizado um filtro por circularidade onde foi considerada a circularidade mínima de 0,3 e máxima de 1 (valor máximo permitido pela biblioteca).

O método de detecção retorna objetos chamados *keypoints*. Portanto, é possível representar as regiões segmentadas através do número de *keypoints* encontrados nas imagens e pelo seu diâmetro. A Tabela 3 a seguir mostra essa representação após a detecção dos *Blobs* para cada um dos métodos de segmentação utilizados. Tomando como exemplo a imagem 1, os métodos 1, 2, 3 e 4 encontraram, respectivamente, 1, 1, 5 e 1 *keypoints*. Portanto, os *keypoints* encontrados pelos métodos 1, 2 e 4 possuem, respectivamente, 29,87, 20,71 e 8,27 *pixels* de diâmetro. Já a soma dos diâmetros dos 5 *keypoints* encontrados pelo método 3 correspondem a 77,13 *pixels* de diâmetro total.

Tabela 3 - Tabela de diâmetros dos pontos encontrados para cada método de segmentação.

IMAGEM	MÉTODO 1	MÉTODO 2	MÉTODO 3	MÉTODO 4
1	29,8718	20,712	77,1314	8,27258
2	0	8,51766	39,0043	149,905
3	158,922	116,97	166,098	99,4518
4	70,9337	56,5199	184,476	219,845
5	0	123,216	0	309,597
6	69,2843	69,4225	47,669	56,7745
7	0	0	105,339	0
8	29,4316	22,0049	52,6074	87,6048
9	168,229	162,875	68,5959	0
10	0	63,5077	33,5335	92,1334
11	0	0	46,6575	45,7638
12	7,07107	7,07107	28,2862	12,4169
13	0	8,88803	77,1192	64,9696
14	0	0	26,9908	67,0275
15	0	8,48987	28,1444	24,0042
16	33,045	61,8994	291,43	307,055
17	59,1834	53,9912	140,533	214,977
18	314,217	78,5413	114,789	338,375
19	272,878	176,229	142,388	349,354
20	0	0	47,8381	48,0568
21	10,2956	0	24,9866	11,4671
22	0	95,6424	567,998	227,489
23	14,9719	101,317	208,529	296,202
24	74,7927	58,4439	129,549	461,436
25	50,6684	22,0472	341,572	312,372
26	0	13,8389	221,703	889,003
27	0	9,22058	28,2162	354,911
28	25,8423	16,5856	58,8442	420,014
29	0	0	36,7961	1205,93
30	0	12,3935	60,9088	65,189
31	0	71,887	11,2443	96,1501
32	0	54,0884	22,1214	67,6141
33	36,4282	35,0728	116,521	160,246
34	69,3749	65,2356	77,641	78,9824
35	52,5928	42,5444	544,509	240,115
36	96,5815	54,3561	182,484	264,233
37	59,8845	65,7145	101,618	340,236
38	64,4724	41,9614	81,4781	137,725
39	0	28,0939	0	120,456
40	0	0	15,829	1189,63
41	144,96	210,564	137,341	693,88
42	0	0	0	126,554
43	104,604	54,6949	166,959	224,015
44	22,3317	13,2744	37,6977	131,542
45	90,07	65,0973	376,96	575,38
46	0	0	444,585	117,325
47	74,6433	33,7078	257,335	392,972
48	0	7,55201	60,0905	186,471
49	26,5302	50,2879	57,8023	198,23
50	31,3028	28,3296	44,766	248,139
51	49,9272	40,7023	57,8609	355,078
52	0	0	59,5258	226,733
53	25,0887	20,7373	611,332	84,6987
54	19,233	11,3973	31,8054	23,803
55	18,2832	17,3161	293,435	10,2828
56	0	0	92,2878	284,608
57	0	17,7036	292,597	121,552
58	35,0807	30,4671	173,996	56,8217
59	0	50,1578	40,3555	193,264
60	30,9761	12,7861	209,014	284,452
61	0	103,71	1668,16	305,735
62	0	24,1318	54,741	0
63	176,782	80,0084	22,3826	171,218
64	0	9,43414	0	12,2356
65	52,3644	33,9642	212,416	148,899
66	0	0	27,5272	96,107
67	25,8328	21,042	112,321	146,639

Fonte: Autor.

6.6 Reconhecimento e Interpretação

Como já mencionado anteriormente neste trabalho, o foco foi a segmentação das regiões infestadas, portanto nesta etapa do processamento de imagens não foi utilizado nenhum método de classificação inteligente, como SVM, redes neurais ou lógica *fuzzy* para classificar as regiões segmentadas como sendo causadas ou não pelo *Epitrix*.

Nesta etapa o único procedimento adotado foi a interpretação dos dados descritos na etapa anterior para estimar o número de mordidas em cada imagem.

Para isso, após a realização da detecção de *Blobs*, o diâmetro do menor objeto encontrado em todo o conjunto de imagens foi tido como o diâmetro de uma mordida. Assim, para estimar o número de mordidas em cada amostra bastou dividir o diâmetro total em cada imagem (mostrados na tabela anterior) por este menor diâmetro encontrado.

Os valores de menor diâmetro encontrados para as metodologias 1, 2, 3 e 4 foram, respectivamente, 6.79525, 6,40312, 6.00873, 4.53909. O resultado final do número de mordidas estimadas para cada imagem e para cada método é mostrado na Tabela 4, que também já traz o número estimado através da análise manual de um técnico, processo que faz parte da validação do trabalho e que será tratado no próximo capítulo.

Como mostra a tabela para a imagem 1, por exemplo, como o diâmetro total do *keypoint* detectado pelo método 1 é de 29,87 *pixels* (Tabela 3), dividimos este valor por 6.7952, onde será encontrado valor próximo a 4. Seguindo o mesmo procedimento, para o método 2 divide-se 20.71 por 6.40, para o método 3 divide-se 77.13 por 6.00 e para o método 4 divide-se 8.22 por 4.53. Desta forma foram obtidos os valores que compõem a Tabela 4.

Tabela 4 - Número de mordidas estimado para cada metodologia.

IMAGEM	MÉTODO 1	MÉTODO 2	MÉTODO 3	MÉTODO 4	TÉCNICO
1	4	3	13	2	3
2	0	1	6	33	5
3	23	18	28	22	22
4	10	9	31	48	16
5	0	19	0	68	1
6	10	11	8	13	1
7	0	0	18	0	0
8	4	3	9	19	4
9	25	25	11	0	0
10	0	10	6	20	3
11	0	0	8	10	4
12	1	1	5	3	2
13	0	1	13	14	12
14	0	0	4	15	2
15	0	1	5	5	5
16	5	10	49	68	18
17	9	8	23	47	3
18	46	12	19	75	4
19	40	28	24	77	29
20	0	0	8	11	5
21	2	0	4	3	3
22	0	15	95	50	8
23	2	16	35	65	2
24	11	9	22	102	12
25	7	3	57	69	6
26	0	2	37	196	3
27	0	1	5	78	2
28	4	3	10	93	5
29	0	0	6	266	40
30	0	2	10	14	28
31	0	11	2	21	0
32	0	8	4	15	0
33	5	5	19	35	9
34	10	10	13	17	12
35	8	7	91	53	11
36	14	8	30	58	16
37	9	10	17	75	20
38	9	7	14	30	12
39	0	4	0	27	0
40	0	0	3	262	10
41	21	33	23	153	40
42	0	0	0	28	0
43	15	9	28	49	39
44	3	2	6	29	4
45	13	10	63	127	96
46	0	0	74	26	25
47	11	5	43	87	20
48	0	1	10	41	2
49	4	8	10	44	36
50	5	4	7	55	23
51	7	6	10	78	12
52	0	0	10	50	0
53	4	3	102	19	2
54	3	2	5	5	4
55	3	3	49	2	0
56	0	0	15	63	30
57	0	3	49	27	0
58	5	5	29	13	71
59	0	8	7	43	6
60	5	2	35	63	23
61	0	16	278	67	6
62	0	4	9	0	23
63	26	12	4	38	3
64	0	1	0	3	4
65	8	5	35	33	40
66	0	0	5	21	13
67	4	3	19	32	41

Fonte: Autor.

7 VALIDAÇÃO

Este capítulo descreve as análises realizadas com os dados obtidos pelo trabalho com o objetivo de medir a acurácia dos métodos desenvolvidos e aplicados para a segmentação de regiões atacadas pelo *Epitrix* em imagens de folhas de tabaco.

Para validar o sistema proposto, o resultado da segmentação das imagens pelo *software* foi comparado com a segmentação realizada manualmente por um técnico especializado. Esta foi realizada no dia 28 de outubro de 2017, pelo Professor da UNISC e co-orientador deste trabalho, Andreas Koehler.

Comparando as regiões segmentadas manualmente com as regiões segmentadas pelo método de limiarização binária (método 1), observa-se que o limiar utilizado foi capaz de segmentar corretamente as regiões esperadas, pois estas, em sua grande maioria, são representadas pelas áreas mais claras da folha, como demonstrado na figura 33, onde os círculos marcam as regiões segmentadas.

Figura 33 - Imagem segmentada manualmente (esquerda) e pelo método 1 (direita).



Fonte: Autor.

Porém, em algumas imagens, como mostrado na imagem 34, o limiar escolhido para o método 1 fica ainda acima do valor das regiões mais claras, e nesses casos, regiões que são marcas da presença do *Epitrix* acabam não sendo segmentadas. De forma semelhante, o limiar também pode ficar muito baixo e acabar segmentando regiões que não deveria, como na figura 35, onde o software segmentou um ponto na veia da folha.

Figura 34 - Imagem segmentada manualmente (esquerda) e pelo método 1 (direita).



Fonte: Autor.

Figura 35 - Imagem segmentada manualmente (esquerda) e pelo método 1 (direita).



Fonte: Autor.

Pelo fato de o limiar depender dos valores de mínimo e máximo da própria imagem, o método 2 consegue ser mais flexível, e em algumas imagens o limiar calculado acaba eliminando regiões que para o método 1 seriam segmentadas incorretamente. Contudo, comparando as imagens segmentados pelo método 2 com a segmentação manual, repetiram-se as mesmas situações observadas para o primeiro método, como na figura 36, onde nenhum ponto foi segmentado pelo software em razão do limiar ainda ser muito grande, e na figura 37, onde foram segmentados pontos claros no meio da veia da folha.

Figura 36 - Imagem segmentada manualmente (esquerda) e pelo método 2 (direita).



Fonte: Autor.

Figura 37 - Imagem segmentada manualmente (esquerda) e pelo método 2 (direita).



Fonte: Autor.

Já a terceira metodologia implementada, que consiste na utilização do método proposto por Barbedo (2016) para a segmentação de regiões claras, se diferencia dos métodos anteriores pelo fato de conseguir realizar a segmentação de forma totalmente automática. Nos casos onde as perfurações causadas pelo *Epitrix* eram realmente nas regiões mais claras das imagens, o método conseguiu segmentá-las de forma correta. Porém, como ele considera todas as partes claras da imagem, o método acaba segmentando regiões que não representam sintomas causados pelo *Epitrix* ou que fazem parte do *background* da imagem, como mostra a figura 38, que ilustra uma injúria causada por outra praga mas que deixa a região da folha com aspecto mais claro.

Figura 38 - Imagem segmentada manualmente (esquerda) e pelo método 3 (direita).



Fonte: Autor.

Já a ultima metodologia utilizada, que realiza a segmentação através do canal H do modelo HSI, foi a que obteve os resultados mais instáveis, como no exemplo da figura 39, onde a segmentação foi correta, e da figura 40, onde a segmentação obteve resultados muito ruins.

Figura 39 - Imagem segmentada manualmente (esquerda) e pelo método 4 (direita).



Fonte: Autor.

Figura 40 - Imagem segmentada manualmente (esquerda) e pelo método 4 (direita).



Fonte: Autor.

De um modo geral, todos os métodos se comportaram de forma diferente dependendo da imagem aplicada. O conjunto utilizado para os testes não foi obtido seguindo um padrão e, portanto, possuem variações grandes de luminosidade, coloração e background entre si, o que levou alguns métodos a cometerem uma série de detecções incorretas. Para o desenvolvimento de todos os métodos, por exemplo, foi definido que o background seria branco ou em tom claro, pois em grande parte das imagens o background respeita a essa regra. Porém, como em algumas delas o background assume um tom mais escuro, o método de segmentação já não é nada eficiente.

A falta dessa padronização traz consigo a percepção da importância da aquisição das imagens para o funcionamento correto de todas as demais etapas. Para o processamento de imagens, é de fundamental importância que haja um padrão na obtenção das mesmas. São fatores como a resolução, iluminação, tipo de sensor, contraste e background que vão, em grande parte dos casos, determinar quais técnicas serão empregadas nas demais etapas do processamento.

Como ressaltado anteriormente, todo o conjunto de imagens utilizado neste trabalho foi analisado manualmente pelo professor, que apontou quais pontos em cada imagem eram realmente causados pelo *Epitrix* e a quantas mordidas cada um desses pontos corresponde. Estes dados foram então comparados com os obtidos pelo software, como mostra a Tabela 5.


Tabela 5 - Comparação da análise manual com as metodologias empregadas.

Imagem	Keypoints	Método 1	Método 2	Método 3	Método 4
1	1	1	1	5	1
2	2	0	1	2	14
3	6	6	9	5	9
4	6	3	3	7	12
5	1	0	6	0	16
6	1	1	1	3	2
7	0	0	0	8	0
8	1	1	1	3	4
9	0	3	7	2	0
10	1	0	3	1	8
11	2	0	0	3	3
12	1	1	1	2	1
13	3	0	1	2	6
14	1	0	0	3	5
15	2	0	1	2	1
16	4	3	5	6	16
17	1	1	1	8	14
18	1	12	6	2	16
19	2	10	7	5	14
20	4	0	0	3	3
21	2	1	0	2	1
22	3	0	5	12	11
23	1	1	6	17	6
24	3	2	3	3	20
25	4	3	1	20	15
26	1	0	2	9	38
27	2	0	1	2	11
28	2	1	1	3	16
29	2	0	0	1	46
30	5	0	1	4	3
31	0	0	7	1	1
32	0	0	5	3	7
33	3	2	1	6	6
34	1	1	2	1	2
35	3	1	1	28	6
36	6	4	3	7	10
37	3	3	5	3	5
38	3	2	2	3	6
39	0	0	1	0	1
40	3	0	0	1	25
41	3	5	4	5	36
42	0	0	0	0	8
43	8	4	4	10	14
44	1	1	1	2	10
45	11	3	3	13	22
46	3	0	0	20	5
47	7	5	3	13	18
48	1	0	1	2	14
49	4	1	2	2	14
50	5	1	1	3	7
51	1	1	1	1	7
52	0	0	0	5	14
53	1	1	1	38	5
54	2	1	1	2	2
55	0	2	2	19	1
56	2	0	0	2	8
57	0	0	2	27	7
58	5	2	2	6	4
59	2	0	6	3	4
60	3	2	1	11	14
61	3	0	5	68	11
62	2	0	2	2	0
63	1	9	5	2	4
64	1	0	1	0	1
65	6	2	2	7	6
66	2	0	0	2	6
67	7	1	1	4	7

Fonte: Autor.

A Figura 41 exemplifica o processo de validação realizado para a imagem 1. Da esquerda para a direita, são mostrados os resultados da segmentação manual, e pelos métodos 1, 2, 3 e 4, respectivamente. A segmentação manual identificou 1 *keypoint* na imagem. Assim, todos os *keypoints* resultantes das metodologias foram comparados com este *keypoint* de modo a validar se a segmentação foi ou não correta. Os métodos 1, 2 e 4 também resultaram em 1 *keypoint* identificado, e comparando-o com a segmentação manual, todos representam o mesmo ponto, sendo, portanto, verdadeiros positivos. Já o método 3 identificou o mesmo *keypoint* segmentado pelo demais, porém também identificou outros 4 *keypoints* incorretos.

Figura 41- Validação da imagem 1.



Fonte: Autor.

Da mesma forma, a Figura 42 exemplifica a validação para a imagem 2. A segmentação manual realizada pelo técnico apontou 2 *keypoints*. A segmentação pelo método 1 não segmentou nenhum dos pontos, já o método 2 identificou 1 *keypoint*, porém este não corresponde a nenhum dos segmentados manualmente, representando um falso positivo. O método 3 conseguiu identificar corretamente um dos *keypoints* e, por fim, o método 4, mesmo tendo identificado corretamente um dos *keypoints*, identificou incorretamente outros 13 em uma região de *background* da imagem.

Figura 42 - Validação da imagem 2.



Fonte: Autor.

A partir dessa análise, é possível determinar a matriz de confusão do sistema proposto, que consiste em uma tabela com uma configuração específica que permite visualizar a *performance* de um sistema.

A Tabela 6 ilustra a composição básica de uma matriz de confusão para duas classes, sendo que TP (*true positives*) representa os verdadeiros positivos, FN (*false negatives*) os falsos negativos, FP (*false positives*) os falsos positivos e TN (*true negatives*) os verdadeiros negativos.

As colunas da matriz representam os números obtidos pelo sistema, e as linhas representam os números reais. No caso do sistema proposto, as classes utilizadas foram se a área segmentada é ou não um ponto de infestação por *Epitrix*.

Tabela 6 - Composição básica da matriz de confusão.

Classe	Ponto segmentado pelo sistema	Ponto não segmentado pelo sistema
É causado pelo <i>Epitrix</i>	TP	FN
Não é causado pelo <i>Epitrix</i>	FP	TN

Fonte: Autor.

Assim, os *keypoints* segmentados pelo *software* que realmente forem causados pelo *Epitrix* (que também forem segmentados pelo técnico) serão os verdadeiros positivos (TP). Se houverem *keypoints* contabilizados pelo sistema proposto, porém não forem segmentados pelo técnico, esses serão considerados falsos positivos (FP). Já os falsos negativos (FN) representarão os *keypoints* que não forem contabilizados pelo *software*, e que forem contabilizados pelo técnico, e, por fim, os verdadeiros negativos (TN) serão os pontos não segmentados pelo sistema e que também não forem consideradas *keypoints* pelo técnico.

As tabelas 7 a 10 a seguir representam, respectivamente, a matriz de confusão para os resultados obtidos com os métodos 1, 2, 3 e 4 de segmentação implementados.

Tabela 7 - Matriz de confusão para o método 1.

	MORDIDA DETECTADA	MORDIDA NÃO DETECTADA
É UMA MORDIDA	54	113
NÃO É UMA MORDIDA	48	0

Fonte: Autor

Tabela 8 - Matriz de confusão para o método 2.

	MORDIDA DETECTADA	MORDIDA NÃO DETECTADA
É UMA MORDIDA	13	116
NÃO É UMA MORDIDA	98	0

Fonte: Autor.

Tabela 9 - Fonte: Matriz de confusão para o método 3.

	MORDIDA DETECTADA	MORDIDA NÃO DETECTADA
É UMA MORDIDA	130	38
NÃO É UMA MORDIDA	340	0

Fonte: Autor.

Tabela 10 - Matriz de confusão para o método 4.

	MORDIDA DETECTADA	MORDIDA NÃO DETECTADA
É UMA MORDIDA	112	55
NÃO É UMA MORDIDA	515	0

Fonte: Autor.

A partir destas classificações é possível calcular métricas para avaliar o trabalho desenvolvido, como a sensibilidade ou taxa de verdadeiros positivos (eq. 6), precisão (eq. 7), acurácia (eq. 8) e taxa de erro (eq. 9)

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN} \quad (6)$$

$$PPV = \frac{TP}{TP + FP} \quad (7)$$

$$ACC = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + TN + FP + FN} \quad (8)$$

$$ERR = \frac{FP + FN}{TP + TN + FN + FP} \quad (9)$$

Calculando estes dados para cada um dos métodos utilizados neste trabalho, foram obtidos os dados expressos na tabela 11.

Tabela 11 - Métricas dos métodos testados.

	Sensibilidade	Precisão	Acurácia	Taxa de erro
Método 1	32.34%	52.94%	25.12%	74.88%
Método 2	10.08%	11.71%	5.73 %	94.27 %
Método 3	77.38%	27.66%	25.59%	74.41%
Método 4	67.07%	17.86%	16.42%	83.58%

Fonte: Autor.

Segundo estes dados, o método 3 obteve a maior sensibilidade, ou seja, o maior número de *keypoints* segmentados corretamente, com 77,38%. Quanto a precisão, que indica o quão relevante são os resultados, o método que obteve a maior taxa foi o método 1, com 52,94%. Já quanto à acurácia, o pior método foi o método 3, com 5,73%.

A precisão e a acurácia são termos que geralmente são confundido entre si. Um método é considerado preciso quando seus resultados são próximos da média dos valores sendo testados. Já a acurácia se refere ao quão próximos os resultados do método estão dos valores verdadeiros sendo testados.

Levando em estas métricas (sensibilidade, precisão e acurácia), os métodos 1 e 3, que correspondem à limiarização com *threshold* fixo e ao método proposto por Barbedo (2016), respectivamente, foram os que obtiveram os melhores resultados.

Ainda assim, todos os métodos obtiveram altas taxas de erro, sendo a menor a do método 3, com 74,41%. Essas taxas elevadas se devem à já mencionada falta de padronização mencionada anteriormente.

Como as imagens não seguem um padrão, um método que funciona muito bem para determinada imagem pode ter um resultado muito ruim ao ser aplicado a outra. Por este motivo que nenhum dos métodos conseguiu minimizar essa taxa de erro.

8 CONCLUSÃO

Existem inúmeras infestações e pragas que atacam plantas e que podem trazer consequências devastadoras para lavouras inteiras, gerando grandes perdas econômicas, sociais e ecológicas. Para evitar tamanhas perdas, a detecção de infestações e doenças em lavouras de forma precisa e no tempo certo é de fundamental importância. Em sua grande maioria, essa detecção é feita visualmente por pessoas. Porém, ela também pode ser feita de forma automatizada através do processamento de imagens.

O sistema proposto neste trabalho tem por objetivo solucionar o problema específico da análise de infestação por *Epitrix* em lavouras de tabaco através de um método computacional utilizando o processamento de imagens.

Para o trabalho proposto foram desenvolvidas quatro metodologias de segmentação diferentes para que fossem testadas e avaliadas. Esses quatro métodos de segmentação foram: a limiarização binária utilizando um *threshold* fixo para todas as imagens, a limiarização binária utilizando um limiar baseado nos mínimos e máximos, a segmentação utilizando o método proposto por Barbedo (2016), e a segmentação através da análise do canal H do modelo HSI.

Após segmentar as regiões lesionadas pelo *Epitrix*, foi aplicado o método de detecção de Blobs sobre as imagens. Essa detecção retorna todos objetos fechados presentes, tornando possível a representação de cada ponto segmentado pelo seu diâmetro, de modo a quantificar a infestação pelo *Epitrix*.

Para validar os métodos desenvolvidos, os resultados obtidos com cada um foram comparadas com a segmentação manual de um conjunto de 67 imagens realizada pelo Prof. Dr. Andreas Koehler, professor na UNISC e co-orientador do trabalho. Através dessa comparação, foi possível obter os valores correspondentes aos verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos para cada um dos métodos e, com isso, determinar a matriz de confusão de cada uma das suas métricas.

A segmentação utilizando limiar fixo e a segmentação pelo método de Barbedo (2016) obtiveram os melhores resultados quanto a acurácia e precisão dos resultados. Porém, todos os métodos testados tiveram altas taxas de erro (todas acima de 70%), sendo que o principal

motivo para tal foi à falta de padronização na primeira etapa do processamento: a aquisição de imagens.

Durante a aquisição de imagens é importante atentar para detalhes como a resolução, sensor utilizado e grau de iluminação, pois todos estes fatores influenciam as demais etapas do processamento. Como sugestão de trabalho futuro fica a realização do acompanhamento durante a fase de coleta das amostras, que não foi possível durante a realização deste trabalho, e do teste dos métodos desenvolvidos utilizando um novo conjunto de imagens.

Outra sugestão de trabalho futuro fica por conta da utilização de um sistema inteligente para a classificação dos pontos segmentados pelo sistema, tais como redes neurais, lógica *fuzzy*, *k-means* ou SVM. Como o foco deste trabalho foi a segmentação das áreas com presença de lesões causadas pelo *Epitrix* nas folhas e tabaco, nenhum destes métodos foi empregado, porém podem ser uma alternativa para a minimização dos erros encontrados durante a validação.

REFERÊNCIAS

- ABDULLAH, N. E. *et al.* *Classification of rubber tree leaf diseases using multilayer perceptron neural network*. The 5th Student Conference on Research and Development – SCOReD, 2007. Não paginado.
- AL-HIARY, H. *et al.* *Fast and accurate detection and classification of plant diseases*. International Journal of Computer Applications, p.31-38, 2011.
- AZMI, M. T. M.; ISA, N. *Orchid disease detection using image processing and fuzzy logic*. International Conference on Electrical, Electronics and System Engineering (ICEESE), p.37-42, 2013.
- BARBEDO, J. G. A. *A new automatic method for disease symptom segmentation in digital photographs of plant leaves*. Eur J Plant Pathol, 2016. Não paginado.
- BARBEDO, J. G. A.; KOENIGKAN, L. V.; SANTOS, T. T. *Identifying multiple plant diseases using digital image processing*. Embrapa Agricultural Informatics, Campinas, SP, Brazil, p. 104-116, 2016.
- BIENKOWSKI, A.; BIENKOWSKAJA, M. J. O. *Key to holarctic species of Epitrix flea beetles with review of their distribution, host plants and history of invasions*. Zootaxa, p.401-435, 2016.
- BREITBACH, A. *A região de Santa Cruz do Sul e o fumo: panorama de uma “especialização” nociva*. Índice Econômico FEE, Porto Alegre, 2014 v. 42, p. 43-62.
- CAMARGO, A.; SMITH, J. S. *Image pattern classification for the identification of disease causing agents in plants*. Computers and Electronics in Agriculture, p.121-125, 2009.
- CAMARGO, A.; SMITH, J. S. *An image-processing based algorithm to automatically identify plant disease visual symptoms*. Biosystems engineering, p.10-21, 2009.

CANNY, J., A Computational Approach To Edge Detection, IEEE Trans. Pattern Analysis and Machine Intelligence, p. 679–698, 1986.

CLEMENT, A. et al. *A new colour vision system to quantify automatically foliar discolouration caused by insect pests feeding on leaf cells*. Biosystems engineering, p.128-140, 2015.

CRANE, R. *Simplified approach to image processing: classical and modern techniques in C*. Prentice Hall, 1997.

CUTHBERTSON, A. G. S. *Chemical and ecological control methods for Epitrix spp*. Global J. Environ. Sci. Manage, p.95-97, 2015.

EYRE, D.; GILTRAP, N. *Epitrix flea beetles: new threats to potato production in Europe*. Pest Manag Sci, p.3-6, 2012.

GALLO, D. et al. *Entomologia Agrícola*. Piracicaba: FEALQ, 2002.

GONZALEZ, R. C.; WOODS, R. E. *Processamento de Imagens Digitais*. 1.ed. São Paulo: Edgard Blücher, 2000.

GREENSTED, *Otsu Thresholding*. Disponível em:

<<http://www.labbookpages.co.uk/software/imgProc/otsuThreshold.html>>. Acesso em: 17 mai. 2017.

GUEDES, J.; SULZBACH, F. *Guia de Identificação e manejo Integrado das Pragas do Fumo*. Santa Maria: Orium, 2006.

HUANG, K. *Application of artificial neural network for detecting phalaenopsis seedling diseases using color and texture features*. Computers and Electronics in Agriculture, p.3-11, 2007.

LEITE, G. L. D. *et al.* *Hosting capacity of horticultural plants for insect pests in Brazil*. Chilean Journal of Agricultural Research, p.383-389, 2011.

KIST, B. B. *et al.* *Anuário brasileiro do tabaco 2016*. Santa Cruz do Sul: Gazeta, 2016.

KOHLER, A.; OLIVEIRA, D.; MORAES, J. *Epitrix* spp. (*Insecta: Coleoptera*) em cultura de tabaco em Santa Cruz do Sul, RS: distribuição espacial e temporal. Disponível em: <<http://online.unisc.br/acadnet/anais/index.php/semic/article/view/11408>>. Acesso em: 21 mar. 2017.

KRUSE, O. M. O. *et al.* *Pixel classification methods for identifying and quantifying leaf surface injury from digital images*. Computers and Electronics in Agriculture, p.155-165, 2014.

MORAES, J. *Comunidades de coleoptera em cultivos de tabaco (Nicotiana Tabacum l.) em Santa Cruz do Sul, RS*. Disponível em: <<http://w3.ufsm.br/ppgagrobio/JonasMoraes.pdf>>. Acesso em: 30 nov. 2017

NEUMANN, R.; ROMERO, M. *Santa Cruz do Sul: Uma potência regional*. Santa Cruz do Sul, RS: Gazeta, 2013.

OLIVEIRA, F.; COSTA, M. C. F. *Dossiê Técnico: Cultivo de fumo*. São Paulo: USP, 2012.

OPENCV. *About OpenCV*. Disponível em: <<http://opencv.org/about.html>>. Acesso em: 24 mar. 2017.

PATIL, S. B.; BODHE, S. K. *Leaf disease severity measurement using image processing*. International Journal of Engineering and Technology Vol.3, p.297-301, 2011.

PHADIKAR, S.; SIL, J.; DAS, A. K. *Rice diseases classification using feature selection and rule generation techniques*. Computers and Electronics in Agriculture, p.76-85, 2013.

PEDRINI, H; SCHWARTZ, W. R. *Análise de Imagens Digitais: princípios, algoritmos e aplicações*. São Paulo: Thomson, 2008.

PHILIP MORRIS INTERNATIONAL. *Cultivo do tabaco*. Disponível em:

<http://www.pmi.com/pt_pt/our_products/growing_tobacco/pages/growing_tobacco.aspx>.

Acesso em: 07 mai. 2017.

RUSS, J. *The Image Processing Handbook*. 2.ed. Estados Unidos: CRC Press, 1994.

SENA JR., D. G. *et al. Fall armyworm damaged maize plant identification using digital images*. Silsoe Research Institute, p.449-454, 2003.

SOUZA CRUZ. *Maior exportadora do Brasil, Souza Cruz produz um dos melhores tabacos do mundo*. Disponível em:

<http://www.souzacruz.com.br/group/sites/SOU_AG6LVH.nsf/vwPagesWebLive/DO9YAEUN>. Acesso em: 12 mai. 2017.

WEIZHENG, S. *et al. Grading method of leaf spot disease based on image processing*. International Conference on Computer Science and Software Engineering, p.491-494, 2008.

ZHANG, F.; ZHANG, X. *Classification and Quality Evaluation of Tobacco Leaves Based on Image Processing and Fuzzy Comprehensive Evaluation*. Sensors, v. 11, p. 2369-2384, 2011.